

ElderCare Insight

คลังข้อมูลและแดชบอร์ดสำหรับธุรกิจสถานดูแลผู้สูงอายุ
จากข้อมูลเปิดของ CMS สหรัฐอเมริกา ปี 2562–2569

เอกสารนี้เป็น **แผนการออกแบบระบบ** ก่อนลงมือพัฒนา ครอบคลุมตั้งแต่
ปัญหาทางธุรกิจ คำถามที่ต้องตอบ แหล่งข้อมูล ทั้ง ห้า แหล่ง ปัญหา
คุณภาพข้อมูลที่ต้องรับมือ ไปจนถึงการประกาศ Grain และผัง Star
Schema

รูปทูลูกบ่งในเอกสารนี้เป็นภาพอธิบายที่วาดขึ้นเอง **ยังไม่มีรูปผลลัพธ์จริง**
เพราะยังไม่ได้รัน ETL ส่วนตัวเลขขนาดข้อมูลทุกตัวมาจากการเปิดไฟล์
จริงแล้ว และตรวจซ้ำได้ด้วยคำสั่งในภาคผนวก ค

เอกสารนี้เป็น **เอกสารทำงาน** จึงยาวกว่ารายงานฉบับส่งที่โจทย์จำกัดไว้
10–15 หน้า รายงานฉบับส่งจะย่อจากภาค 1–4 ของเอกสารนี้

กลุ่มที่ _____ สมาชิก: _____ , _____ , _____

ข้อมูล: CMS Provider Data Catalog — Nursing Homes (data.cms.gov) · สถานะ: ออกแบบเสร็จ ยังไม่เริ่ม ETL
ปรับปรุงล่าสุด: 12 สิงหาคม 2569

สารบัญ


เอกสารนี้อ่านอย่างไร	4
1 ธุรกิจและคำถาม — เราจะตอบอะไร	6
1 ธุรกิจสถานดูแลผู้สูงอายุทำงานอย่างไร	6
1.1 ปัญหาทางธุรกิจที่ต้องการแก้	7
2 ใครใช้ข้อมูลนี้ (Stakeholders)	8
3 คำถามทางธุรกิจแปดข้อ	8
4 Measures และกับดักของการรวมค่า	9
2 แหล่งข้อมูล — มาจากไหน มีอะไร ใช้ทำอะไร	11
5 ภาพรวมทั้งห้าแหล่ง	11
6 แหล่งที่ 1 — CMS Nursing Homes Archived Snapshots	11
6.1 มาจากไหน	11
6.2 มีอะไรอยู่ข้างใน	12
6.3 ใช้ทำอะไร	13
7 แหล่งที่ 2 — CMS Provider Data Catalog REST API	13
7.1 มาจากไหน	13
7.2 มีอะไร	14
7.3 ใช้ทำอะไร	14
8 แหล่งที่ 3 — SNF VBP Facility Performance	15
8.1 มาจากไหน มีอะไร	15
8.2 ใช้ทำอะไร	15
9 แหล่งเสริมอีกสองแหล่ง	16
9.1 S4 — ประชากรอายุ 65 ปีขึ้นไป รายรัฐ	16
9.2 S5 — ตาราง lookup ของ CMS	16

10 ตารางสืบย้อน — แหล่งไหนตอบคำถามไหน	16
3 คุณภาพข้อมูล — อะไรพังบ้าง	18
11 ปัญหาแปดประเภทและวิธีรับมือ	19
4 คลังข้อมูล — Grain และ Star Schema	21
12 สี่ขั้นตอนของ Kimball	21
12.1 ขั้นที่ 1 — เลือกกระบวนการทางธุรกิจ	21
13 ขั้นที่ 2 — ประกาศ Grain	21
13.1 ทำไมสองตารางนี้ถึงรวมกันไม่ได้	22
14 ขั้นที่ 3 — เลือก Dimensions	23
14.1 SCD ชนิดที่ 2 ทำงานอย่างไร	24
15 ขั้นที่ 4 — ผัง Star Schema	25
16 ข้อควรระวังของผังนี้	26
5 ETL และ Dashboard — แผนงานถัดไป	27
17 กระบวนการ ETL ห้าขั้น	27
18 แผนแดชบอร์ด	27
19 คะแนนพิเศษที่ตั้งเป้า	28
20 สิ่งที่ต้องทำก่อนเริ่มพัฒนา	28
ภาคผนวก	30
ภาคผนวก	30
A อภิธานศัพท์ ไทย-อังกฤษ	30
B คอลัมน์สำคัญของ NH_ProviderInfo ที่จะใช้จริง	31

C คำสั่งที่ใช้ตรวจสอบตัวเลขในเอกสารนี้	31
D แหล่งอ้างอิง	32

เอกสารนี้อ่านอย่างไร

เอกสารแบ่งเป็นห้าภาค เรียงตามทางเดินของข้อมูลจริง ไม่ใช่เรียงตามหัวข้อทฤษฎี ผู้อ่านที่หลงทางสามารถถามตัวเองว่า “ตอนนี้ข้อมูลอยู่ตรงไหนของท่อ” แล้วจะรู้ทันทีว่าอยู่ภาคใด



รูปที่ 1: แผนที่ของเอกสาร ห้าภาคเรียงตามทางเดินของข้อมูล จากคำถามทางธุรกิจไปจนถึงหน้าจอที่ผู้บริหารเห็น

ระบบที่ใช้ตลอดเอกสาร

สีสี่สีนี้แทน ระยะของไปป์ไลน์ และจะถูกใช้ความหมายเดิมทุกที่ ทั้งในเนื้อความ ในผัง และในกราฟของแดชบอร์ดภายหลัง ชุดสีเป็น Okabe-Ito ซึ่งปลอดภัยต่อผู้มีภาวะตาบอดสี

- **แหล่งข้อมูล** — ข้อมูลดิบจากภายนอกที่เรายังทำอะไรไม่ได้
- **ETL** — ขั้นตอนแปลงข้อมูล จุดที่ความผิดพลาดเกิดขึ้นมากที่สุด
- **คลังข้อมูล** — ตาราง Fact และ Dimension ที่ออกแบบเอง
- **Dashboard** — สิ่งที่ผู้ใช้เห็นและตัดสินใจจากมัน

กล่องสีแบบ และความหมายของมัน

กล่องด้านล่างนี้ คือคำนิยามของตัวมันเอง — เนื้อหาในกล่องบอกว่ากล่องสีนั้นใช้เมื่อไร

กล่องน้ำเงิน: ข้อสรุปที่ต้องจำ

ใช้กับใจความที่ร้อยหลายบทเข้าด้วยกัน ถ้าอ่านเอกสารนี้แบบเร็ว ให้อ่านเฉพาะกล่องน้ำเงิน

กล่องส้ม: กับดัก หรือข้อแม้ที่ถ้าลืมแล้วข้อสรุปจะผิด

ใช้กับสมมติฐานที่เปราะ และกับจุดที่คนทำงาน DW พลาดกันบ่อย

กล่องเขียว: สิ่งที่ต้องตรวจสอบกับข้อมูลจริงแล้ว

ใช้เฉพาะกับตัวเลขหรือข้อเท็จจริงที่เปิดไฟล์ดูจริงหรือเรียก API จริงแล้ว ไม่ใช่กับสิ่งที่คาดว่าจะเป็น

กล่องแดง: วิธีที่ผิดจริง ๆ

ใช้น้อยที่สุด — เฉพาะแนวทางที่ถ้าทำตามแล้วผลลัพธ์จะผิด ไม่ใช่แค่ไม่สวย

สถานะของข้อมูลในเอกสารนี้

ข้อความที่กำกับ **[ตรวจแล้ว]** หมายถึงเปิดไฟล์จริงหรือเรียก API จริงแล้ว ส่วน **[ยังไม่ตรวจ]** คือสมมติฐานที่ยังต้องพิสูจน์ในขั้น ETL — อย่าอ้างอิงข้อความกลุ่มหลัง ในรายงานฉบับส่งจนกว่าจะตรวจแล้ว

ภาคที่ 1

ธุรกิจและคำถาม — เราจะตอบอะไร

ภาคนี้ตอบคำถามว่า: ก่อนแต่ละข้อมูลแม้แต่แถวเดียว เราต้องการรู้อะไรกันแน่

1 ธุรกิจสถานดูแลผู้สูงอายุทำงานอย่างไร

สถานดูแลผู้สูงอายุแบบ Skilled Nursing Facility (SNF) ในสหรัฐอเมริกา เป็นธุรกิจที่มีลักษณะเฉพาะสามอย่างพร้อมกัน

1. รายได้ผูกกับอัตราการเข้าพัก (occupancy) เพราะต้นทุนต่อเตียงเป็นต้นทุนคงที่ เพียงว่างหนึ่งเตียงคือรายได้ที่หายไปโดยที่ต้นทุนไม่ลด
2. ต้นทุนหลักคือค่าแรงพยาบาลและผู้ช่วยพยาบาล ซึ่งกินสัดส่วนต้นทุนดำเนินงานสูงสุด
3. ถูกกำกับเข้มโดยรัฐ ผ่านระบบให้คะแนน Five-Star Quality Rating การตรวจสอบการประกอบการ และบทลงโทษทางการเงิน

สิ่งที่ทำให้ธุรกิจนี้น่าสนใจในเชิงวิเคราะห์คือ ทั้งสามอย่างนี้ ไม่ได้แยกกัน แต่ป้อนกลับเข้าหากันเป็นวงจร



รูปที่ 2: วงจรป้อนกลับของธุรกิจสถานดูแลผู้สูงอายุ — คะแนนคุณภาพไม่ใช่แค่ตัวชี้วัด แต่เป็นตัวขับเคลื่อนระบบ คลังข้อมูลนี้จึงต้องเชื่อมคุณภาพ ต้นทุนแรงงาน และค่าปรับ ไว้ในที่เดียวกัน

ทำไมต้องสร้างคลังข้อมูลเอง ทั้งที่ CMS เปิดข้อมูลให้ดูอยู่แล้ว

เว็บของ CMS ให้ดูได้เฉพาะ สถานะปัจจุบัน ของแต่ละแห่ง ข้อมูลเดือนเก่าถูกย้ายไป คลังเอกสารเก่าเป็นไฟล์บีบอัดแยกกันเดือนต่อเดือน ไม่มีใครต่อให้เป็นอนุกรมเวลา คำถามอย่าง “สถานที่ไหนคะแนนกำลังตกต่อเนื่อง” หรือ “อุตสาหกรรมฟื้นจาก COVID แล้วหรือยัง” จึงตอบไม่ได้เลยถ้าไม่ประกอบคลังข้อมูลขึ้นมาเอง — นี่คือเหตุผลที่โครงการนี้มีอยู่

1.1 ปัญหาทางธุรกิจที่ต้องการแก้

เอกสารนี้สมมติบทบาทเป็นทีมวางแผนกลยุทธ์ของ ผู้ประกอบการเครือข่ายสถานดูแลผู้สูงอายุ หรือกองทุนที่กำลังพิจารณาลงทุนในธุรกิจนี้ ปัญหาที่เผชิญมีสี่ข้อ

1. ตัดสินใจขยายตลาดโดยไม่มีข้อมูลรองรับ — ไม่รู้ว่ารัฐใดมีอุปสงค์เหลืออยู่ (ผู้สูงอายุมากแต่เตียงน้อย) และคู่แข่งในพื้นที่นั้นอ่อนแอพอให้เข้าไปแข่งได้
2. ไม่รู้ว่าควรลงทุนด้านพนักงานเท่าไรจึงคุ้ม — การเพิ่มชั่วโมงพยาบาลคือต้นทุน ที่เห็นทันทีในงบเดือนนี้ แต่ผลตอบแทนมาช้าและวัดยาก
3. ความเสี่ยงด้านกฎระเบียบมองไม่เห็นล่วงหน้า — รู้ตัวอีกทีเมื่อถูกปรับไปแล้ว ทั้งที่สัญญาณเตือนปรากฏในข้อมูลมาก่อนหลายเดือน
4. ข้อมูลกระจายกระจายตามเวลา — ตามที่อธิบายในกล่องน้ำเงินด้านบน

2 ใครใช้ข้อมูลนี้ (Stakeholders)

ผู้ใช้	ต้องตัดสินใจอะไร	ต้องการอะไรจากแดชบอร์ด
CEO / หัวหน้าฝ่ายขาย กิจการ	เลือกตลาดที่จะเข้าไปลงทุนหรือซื้อ กิจการ	ภาพเปรียบเทียบรายรัฐ: อุปสงค์ เทียบ อุปทาน เทียบ คุณภาพคู่แข่ง
COO / ผู้จัดการภูมิภาค	จัดลำดับว่าจะเข้าไปแก้ที่ไหนก่อน	รายชื่อสถานที่ที่คะแนนกำลังตก พร้อมระดับ ความเร่งด่วน
ผู้อำนวยการฝ่ายบุคคล	วางแผนอัตรากำลังและลดการลา ออก	ความสัมพันธ์ ชั่วโมงพยาบาล – อัตราลาออก – คะแนนคุณภาพ
CFO / นักลงทุนสัมพันธ์	ประเมินผลตอบแทนและความเสี่ยง	มูลค่าค่าปรับ อัตราการเข้าพัก และตัวคูณเงิน งูใจ VBP
ฝ่ายกำกับปฏิบัติตาม กฎ	บริหารความเสี่ยงด้านกฎระเบียบ	แนวโน้มค่าปรับ ประเภทข้อบกพร่องที่พบบ่อย สถานะ Special Focus
(ภายนอก) ครอบครัวผู้สูง อายุ	เลือกสถานที่ให้ญาติผู้ใหญ่	เปรียบเทียบคุณภาพของสถานที่ในพื้นที่ เดียวกัน

ตารางที่ 1: ผู้ใช้งานข้อมูลหกกลุ่ม คอลัมน์กลางคือสิ่งที่ทำให้แดชบอร์ดมีประโยชน์จริง — ถ้ากราฟใดไม่ช่วยตัดสินใจข้อใดข้อหนึ่งในคอลัมน์นี้ ก็ไม่ควรอยู่บนหน้าจอ

3 คำถามทางธุรกิจแปดข้อ

โจทย์กำหนดอย่างน้อย 5 ข้อ ตั้งไว้ 8 ข้อเพื่อให้มีระยะเผื่อ คอลัมน์ขวาสุดคือเครื่องมือตรวจสอบตัวเอง: ถ้าคำถามข้อใดไม่มีตารางรองรับ แปลว่าผังที่ออกแบบไว้ยังไม่พอ

#	คำถาม	ผู้ใช้	ตอบด้วยตารางใด
BQ1	รัฐใดนำเข้าไปลงทุนที่สุด เมื่อดูจำนวนเตียงต่อประชากรสูง อายุพันคน อัตราการเข้าพักเฉลี่ย และคะแนนคุณภาพของคู่แข่ง	CEO	Fact_Facility_Monthly × Dim_Geography + ข้อมูลประชากร
BQ2	รูปแบบการถือครองแบบใดให้ผลต่างกันอย่างไร ทั้งด้านคุณภาพ ชั่วโมงพยาบาล และค่าปรับต่อเตียง	CEO, CFO	ทั้งสอง Fact × Dim_Ownership
BQ3	ชั่วโมงพยาบาลต่อผู้พักอาศัยต่อวันสัมพันธ์กับคะแนนดาวและค่าปรับอย่างไร และจุดคุ้มอยู่ที่ระดับใด	ฝ่ายบุคคล, CFO	Fact_Facility_Monthly
BQ4	อัตราการลาออกของพยาบาลสูงแค่ไหนจึงเริ่มลดคุณภาพและอัตราการเข้าพัก	ฝ่ายบุคคล	Fact_Facility_Monthly
BQ5	แนวโน้มปี 2562–2569 ของอัตราการเข้าพัก ชั่วโมงพยาบาล และคะแนนดาว เป็นอย่างไร พิจารณาจาก COVID แล้วหรือยัง	CEO, CFO	Fact_Facility_Monthly × Dim_Date
BQ6	สถานที่ใดกำลังเสื่อมคุณภาพและมีแนวโน้มถูกลงโทษ	COO, กำกับกฎ	ทั้งสอง Fact × Dim_Facility (SCD2)
BQ7	ค่าปรับกระจุกตัวที่รัฐใดและช่วงเวลาใด รัฐใดบังคับใช้กฎหมายมากที่สุดต่อเตียง	กำกับกฎ	Fact_Penalty_Event × Dim_Geography, Dim_Date
BQ8	เครือข่ายขนาดใหญ่ได้เปรียบจริงหรือไม่ — คุณภาพดีกว่า หรือแค่กดดันทุนแรงงาน	CEO	Fact_Facility_Monthly × Dim_Chain

ตารางที่ 2: คำถามทางธุรกิจแปดข้อ ทุกข้อมีตารางรองรับครบ ซึ่งเป็นหลักฐานว่าผัง Star Schema ในภาค 4 ออกแบบมาพอดีกับสิ่งที่ต้องตอบ ไม่ได้ออกแบบลอย ๆ

BQ1 เป็นข้อเดียวที่พึ่งข้อมูลนอก CMS

ถ้าดึงข้อมูลประชากรอายุ 65 ปีขึ้นไปไม่สำเร็จ จะลดรูปเหลือ “เตียงต่อประชากรทั้งรัฐ” หรือตัด BQ1 ทิ้งแล้วยังเหลือ 7 ข้อ ซึ่งยังเกินเกณฑ์ วางแผนทางถอยไว้ตั้งแต่ตอนนี เพราะถ้าไปเจอตอนเขียนแดชบอร์ดจะแก้ไม่ทัน

4 Measures และกับดักของการรวมค่า

โจทย์กำหนดอย่างน้อย 3 ตัว และให้อธิบาย *ความหมาย วิธีคำนวณ และประโยชน์* เอกสารนี้เพิ่มคอลัมน์ **การรวมค่า (additivity)** เข้าไปด้วย เพราะเป็นสิ่งที่ตัดสินใจว่า แดชบอร์ดจะสรุปตัวเลขถูกหรือผิด

Measure	วิธีคำนวณ	การรวมค่า	ความหมายและประโยชน์
M1 อัตราการเข้าพัก	SUM(avg_residents_per_day) / SUM(certified_beds)	รวมตรง ๆ ไม่ได้ (อัตราส่วน)	ตัวชี้วัดรายได้หลัก ต่ำกว่า 80% มักหมายถึงขาดทุน
M2 วัน-ผู้พักอาศัย	avg_residents_per_day × จำนวนวันในงวด	รวมได้	ปริมาณบริการที่ขายได้จริง ใช้ถ่วงน้ำหนัก measure อื่น
M3 ชั่วโมงพยาบาลต่อคนต่อวัน	reported_total_nurse_hprd (ถ่วงน้ำหนักด้วย M2)	รวมตรง ๆ ไม่ได้	ตัวแทนของต้นทุนแรงงาน และเป็นตัวพยากรณ์คุณภาพที่แรงที่สุด
M4 อัตราการลาออก	total_nursing_turnover_pct (ถ่วงน้ำหนักด้วย M2)	รวมตรง ๆ ไม่ได้	ต้นทุนแฝงจากการสรรหาและฝึกอบรม และเป็นสัญญาณเตือนคุณภาพ
M5 มูลค่าค่าปรับ	SUM(fine_amount_usd) จาก Fact_Penalty_Event	รวมได้	ต้นทุนความเสี่ยงด้านกฎระเบียบที่จับต้องได้เป็นเงิน
M6 จำนวนครั้งที่ถูกลงโทษ	COUNT(*) จาก Fact_Penalty_Event	รวมได้	ใช้คู่กับ M5 เพื่อแยก “ถูกปรับบ่อยที่ละน้อย” ออกจาก “ถูกปรับหนักครั้งเดียว”
M7 คะแนนดาวเฉลี่ย	AVG(overall_rating) ช่วง 1–5	รวมตรง ๆ ไม่ได้	ตัวแปรที่ครอบคลุมผู้สูงอายุใช้ตัดสินใจมากที่สุด
M8 จำนวนข้อบกพร่อง	SUM(cycle1_total_deficiencies)	รวมได้	ตัวชี้วัดปฏิบัติการที่ “มาก่อน” การถูกปรับ
M9 ค่าปรับต่อวัน-ผู้พักอาศัย	M5 / M2	คำนวณตอน query	ทำให้เทียบความเสี่ยงระหว่างสถานที่ต่างขนาดได้อย่างเป็นธรรม
M10 เติงต่อผู้สูงอายุพันคน	SUM(certified_beds) / (ประชากร 65+ / 1000)	คำนวณตอน query	ความอึดตัวของตลาด ค่าต่ำแปลว่ายังมีอุปสงค์เหลือ (ใช้ตอบ BQ1)

ตารางที่ 3: Measures สิบตัว M1–M8 เก็บในตาราง Fact ส่วน M9–M10 ไม่เก็บแต่คำนวณตอนสอบถาม เพราะเป็นอัตราส่วนที่หาได้จากตัวอื่น การเก็บซ้ำมีแต่จะทำให้ข้อมูลซ้ำกันเอง

ความผิดพลาดที่พบบ่อยที่สุดในงานคลังข้อมูล: เฉลี่ยของอัตราส่วน

สมมติมีสองแห่ง แห่งแรก 10 เติง มีผู้พัก 5 คน (50%) แห่งที่สอง 200 เติง มีผู้พัก 180 คน (90%)

AVG(occupancy) ให้ $(50 + 90)/2 = 70\%$

วิธีที่ถูกคือ SUM(residents)/SUM(beds) ให้ $185/210 = 88.1\%$

ต่างกัน 18 จุด และค่าที่ผิดจะ *ต่ำกว่าความจริงเสมอ* เมื่อสถานที่ใหญ่ทำได้ดีกว่า แดชบอร์ดที่ลากอัตราส่วนไปวางแล้วให้เครื่องมือเฉลี่ยให้เอง จะผิดแบบนี้ทุกครั้ง จึงต้องเก็บ **ตัวตั้งและตัวหารแยกกัน** ในตาราง Fact แล้วหารตอนแสดงผล

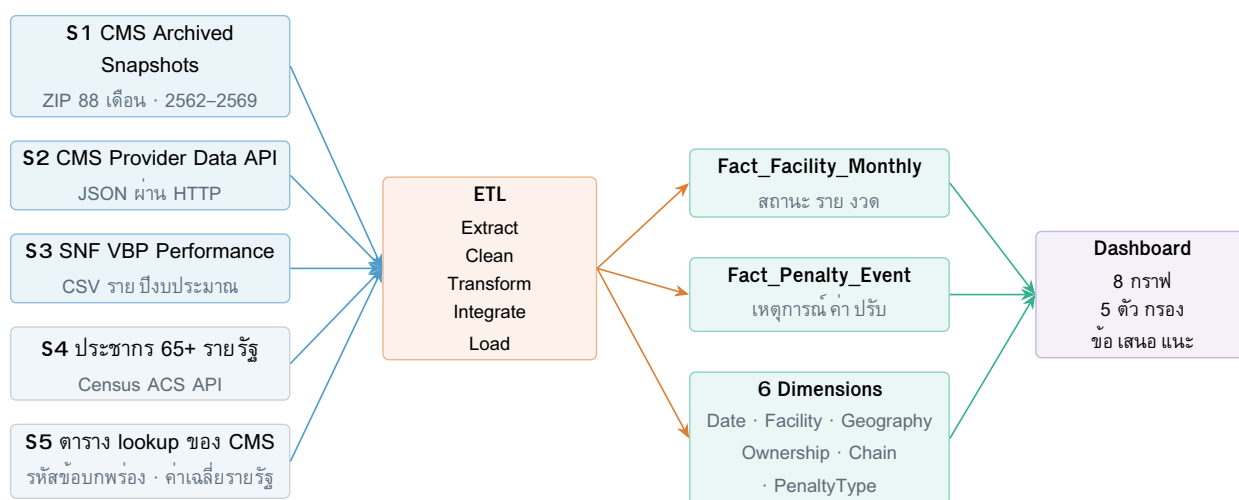
ภาคที่ 2

แหล่งข้อมูล — มาจากไหน มีอะไร ใช้ทำอะไร

ภาคนี้ตอบคำถามว่า: ข้อมูลทุกตัวเลขที่จะขึ้นบนแดชบอร์ด สืบกลับไปถึงไฟล์ไหนบนเซิร์ฟเวอร์ใคร

โจทย์กำหนดให้ใช้ อย่างน้อย 3 แหล่ง และอย่างน้อยหนึ่งแหล่งต้องซับซ้อนกว่า CSV ตารางทั่วไป โครงการนี้ใช้ 3 แหล่งหลัก และ 2 แหล่งเสริม

5 ภาพรวมทั้งห้าแหล่ง



รูปที่ 3: ทางเดินของข้อมูลทั้งระบบ ห้าแหล่งไหลผ่าน ETL ชัดเดียวลงสู่สองตาราง Fact และหกตาราง Dimension แล้วจึงขึ้นแดชบอร์ด สีในผังนี้คือสีเดียวกับที่ใช้เรียกกระยะต่าง ๆ ตลอดเอกสาร

6 แหล่งที่ 1 — CMS Nursing Homes Archived Snapshots

6.1 มาจากไหน

- ผู้เผยแพร่: Centers for Medicare & Medicaid Services (CMS) กระทรวงสาธารณสุขสหรัฐอเมริกา ผ่านระบบ Provider Data Catalog
- หน้าที่เว็บ: <https://data.cms.gov/provider-data/archived-data/nursing-homes>
- ลิงก์ไฟล์จริง: หน้านั้นเป็นแอปแบบ JavaScript จึงไม่มีลิงก์ในโค้ด HTML ต้องดึงรายการผ่าน API (แหล่ง S2) ซึ่งคืนที่อยู่ไฟล์ในรูปแบบ
/provider-data/sites/default/files/dataset-archives/theme/
nursing-homes/nursing-homes_2026-06-24.zip
- สิทธิการใช้งาน: ข้อมูลสาธารณะของรัฐบาลสหรัฐฯ ใช้ได้เสรี ต้องอ้างอิงแหล่งที่มา

สิ่งที่ตรวจสอบแล้วเกี่ยวกับแหล่งนี้

มี 88 snapshot รายเดือน ตั้งแต่ 17 ม.ค. 2562 ถึง 6 ส.ค. 2569 และมีชุดรวมรายปีอีก 8 ชุด ไฟล์รายเดือนมีขนาดราว 32–40 MB เมื่อบีบอัด ยกเว้นบางเดือนที่ผิดปกติ เช่น 29 ก.ค. 2569 มีขนาด 622 MB และ 6 ส.ค. 2569 มีเพียง 3.5 MB (น่าจะเป็นการอัปเดตบางส่วน) — ขั้นตอน ETL จึงต้องไม่สมมติว่าทุก snapshot มีไฟล์ครบเท่ากัน

6.2 มีอะไรอยู่ข้างใน

เปิดไฟล์ nursing-homes_2026-06-24.zip (38 MB บีบอัด) พบ 20 ไฟล์ รวม 614 MB เมื่อคลาย รายการด้านล่างคือของจริงทั้งหมด

ไฟล์	แถว	คอลัมน์	เนื้อหา
NH_ProviderInfo	14,695	99	โปรไฟล์ คะแนนดาว ชั่วโมงพยาบาล อัตราลาออก เต็ม ที่ตั้ง เจ้าของ
NH_Penalties	16,180	14	ค่าปรับและการระงับการจ่ายเงินรายรายการ พร้อมวันที่และจำนวนเงิน
NH_SurveySummary	43,952	41	สรุปผลการตรวจแยกตามหมวดข้อบกพร่อง 30 หมวด
FY_2026_SNF_VBP_Facility_Performance	13,900	49	คะแนนและตัวคูณเงินจูงใจ (ดูแหล่ง S3)
NH_CitationDescriptions	643	5	คำอธิบายรหัสข้อบกพร่องแต่ละรหัส
NH_StateUSAverages	54	51	ค่าเฉลี่ยรายรัฐและระดับประเทศ
NH_HealthCitations	165 MB		ข้อบกพร่องรายรายการ ไฟล์ใหญ่ที่สุด
NH_Ownership	56 MB		นิติบุคคลผู้ถือครองแต่ละราย หนึ่งแห่งมีได้หลายราย
NH_QualityMsr_MDS	75 MB		ตัวชี้วัดคุณภาพจากแบบประเมินผู้พักอาศัย
NH_QualityMsr_Claims	17 MB		ตัวชี้วัดคุณภาพจากข้อมูลการเบิกจ่าย
NH_FireSafetyCitations	69 MB		ข้อบกพร่องด้านความปลอดภัยจากอัคคีภัย
NH_SurveyDates	7.8 MB		วันที่เข้าตรวจแต่ละรอบ

อีก 8 ไฟล์ที่เหลือเป็นข้อมูลประกอบขนาดเล็กและคู่มือ NH_Data_Dictionary.pdf

ตารางที่ 4: ไฟล์ทั้งหมดใน snapshot เดือนมิถุนายน 2569 ตัวเลขแถวและคอลัมน์มาจากการเปิดไฟล์จริง โครงงานนี้จะใช้เพียง 6 ไฟล์แรก ส่วนที่เหลือระบุไว้เพื่อให้เห็นว่าตัดอะไรออกและตัดเพราะอะไร

6.3 ใช้ทำอะไร

ไฟล์	ป้อนตารางใด	ตอบคำถามข้อใด
NH_ProviderInfo	Fact_Facility_Monthly และ Dimension ทั้ง 5 ตัวแรก	BQ1–BQ6, BQ8
NH_Penalties	Fact_Penalty_Event, Dim_Penalty_Type	BQ2, BQ6, BQ7
NH_SurveySummary	สำรองไว้สำหรับ Fact ที่ 3 (ถ้ามีเวลา)	ขยาย BQ7
NH_CitationDescriptions	ตาราง lookup แพลทฟอร์มเป็นคำอธิบาย	BQ7
NH_StateUSAverages	ค่าอ้างอิงเปรียบเทียบบนกราฟ	BQ1, BQ5

ตารางที่ 5: การจับคู่ไฟล์กับตารางปลายทาง ไฟล์ที่ไม่ปรากฏในตารางนี้จะไม่ถูกคลายออกจาก ZIP เลย เพื่อให้เสียเวลาและพื้นที่ไปกับข้อมูล 165 MB ที่ไม่ได้ใช้

ทำไมแหล่งนี้จึงนับว่า “ซับซ้อนกว่า CSV ตารางทั่วไป”

โจทย์ยกตัวอย่างความซับซ้อนไว้ข้อหนึ่งว่า “ข้อมูลจากหลายไฟล์หรือหลายช่วงเวลา” ซึ่งแหล่งนี้ตรงเป๊ะ: ต้องวนดาวน์โหลดหลายสิบไฟล์ คลายบีบอัด จับคู่ชื่อไฟล์ที่ เปลี่ยนไปตามเดือน (NH_ProviderInfo_Jun2026.csv กลายเป็น NH_ProviderInfo_Sep2026.csv) แล้วต่อกันเป็นอนุกรมเวลาเอง ไม่มีไฟล์ใดไฟล์หนึ่งที่เปิดแล้วได้ข้อมูลย้อนหลังทันที

ขอบเขตที่ตัดสินใจไว้แล้ว: โหลดรายไตรมาส ไม่ใช่ทุกเดือน

88 snapshot × 38 MB คือการดาวน์โหลดราว 3.3 GB และคะแนนดาวเปลี่ยนช้าเกินกว่าจะ ให้ข้อมูลเพิ่มรายเดือน จึงเลือกไตรมาสละหนึ่ง snapshot ได้ประมาณ 28–31 จุดเวลา ครอบคลุมช่วงเดียวกัน แต่ดาวน์โหลดลดลงเหลือราวหนึ่งในสาม ถ้าภายหลังพบว่าความละเอียดไม่พอ เพิ่ม snapshot ได้โดยไม่ต้องรื้อผัง เพราะ Grain กำหนดไว้ที่ “ต่อ snapshot” ไม่ใช่ “ต่อเดือน”

7 แหล่งที่ 2 — CMS Provider Data Catalog REST API

7.1 มาจากไหน

เป็น API สาธารณะของ CMS ที่อยู่ใต้โดเมนเดียวกัน ใช้สามปลายทาง

#	ปลายทาง (ต่อท้าย https://data.cms.gov/provider-data/api/1/)	คืออะไร
A	archive/aggregate/theme/nursing-homes/relative	รายการ snapshot ทั้งหมด 96 รายการ พร้อม URL ขนาด และวันที่
B	metastore/schemas/dataset/items	แคตตาล็อกชุดข้อมูลทั้งหมด 234 ชุด ในจำนวนนี้เป็นของ Nursing Homes 11 ชุด
C	datastore/query/4pq5-n9py/0?limit=1	ข้อมูลแถวจริงของชุด Provider Information เป็น JSON ชื่อเคสแบบ snake_case

ตารางที่ 6: สามปลายทางของ API ที่โครงการนี้ใช้ รหัสอย่าง 4pq5-n9py คือรหัสชุดข้อมูลที่ได้มาจากปลายทาง B จึงไม่ต้องจดไว้เอง

7.2 มีอะไร

ปลายทาง A คืนข้อมูลหน้าตาแบบนี้ (ตัดมาหนึ่งรายการ)

```
{
  "name": "Theme: nursing-homes (2026-06-24)",
  "id": "8681",
  "type": "theme",
  "theme": "nursing-homes",
  "url": "/provider-data/sites/default/files/dataset-archives/theme/nursing-homes/nursing-homes_2026-06-24.zip",
  "size": "38990000",
  "date": "2026-06-24",
  "access_level": "public"
}
```

ส่วนปลายทาง C คืนแถวข้อมูลจริง ตัวอย่างแถวแรกคือ

```
{
  "cms_certification_number_ccn": "015009",
  "provider_name": "BURNS NURSING HOME, INC.",
  "citytown": "RUSSELLVILLE",
  "state": "AL",
  "zip_code": "35653",
  "ownership_type": "For profit - Corporation",
  "number_of_certified_beds": "57",
  "average_number_of_residents_per_day": "51.6",
  ...
}
```

แถวตัวอย่างนี้เรียกมาจริงแล้ว และใช้เป็นกรณีทดสอบได้

สถานที่ CCN 015009 มี 57 เตียง มีผู้พักอาศัยเฉลี่ย 51.6 คนต่อวัน $\Rightarrow$ อัตราการเข้าพัก $51.6/57 = 90.5\%$ ตัวเลขชุดนี้จะถูกใช้เป็น *แถวทดสอบ* ของ ETL: ถ้ารันแล้วแถวของ CCN 015009 ไม่ได้ค่า 90.5% แปลว่าทอปปิง ก่อนจะไปดูอย่างอื่น

7.3 ใช้ทำอะไร

- ค้นหา snapshot อัตโนมัติ (ปลายทาง A) — ทำให้ ETL รู้เองว่ามีข้อมูลเดือนใหม่ โดยไม่ต้องมีคนไปคัดลอกลิงก์มาแปะ นี่คือสิ่งที่ทำให้ *รันซ้ำได้* ตามที่โจทย์บังคับ
- ทำ Incremental Load — เทียบรายการจาก A กับไฟล์ที่มีอยู่แล้วในเครื่อง แล้วโหลดเฉพาะส่วนต่าง

3. ตรวจสอบความถูกต้องหลัง Load — ดึงข้อมูลปัจจุบันจากปลายทาง C มาเทียบกับแถวล่าสุดในคลังข้อมูล ถ้าไม่ตรงแปลว่า ETL แปลงค่าผิดที่ไหนสักแห่ง

API คือสิ่งที่แยก “ไปป์ไลน์” ออกจาก “การดาวน์โหลดด้วยมือ”

โจทย์ระบุชัดว่า “กระบวนการควรสามารถรันซ้ำได้ โดยไม่ต้องแก้ไขข้อมูลด้วยมือทุกขั้นตอน” และให้คะแนนพิเศษกับ การใช้ API กับ การทำ Incremental Load ปลายทาง A ตัวเดียวตอบทั้งสามข้อนี้พร้อมกัน ด้วยโค้ดไม่กี่บรรทัด

8 แหล่งที่ 3 — SNF VBP Facility Performance

8.1 มาจากไหน มีอะไร

ไฟล์ FY_2026_SNF_VBP_Facility_Performance.csv อยู่ใน ZIP เดียวกับแหล่ง S1 แต่นับเป็นคนละแหล่ง เพราะเป็นคนละโครงการของ CMS คนละรอบเวลา และ คนละ Grain — เป็นข้อมูลราย ปีงบประมาณ ขณะที่ทุกอย่างใน S1 เป็นรายเดือน

ขนาด 13,900 แถว × 49 คอลัมน์ [ตรวจแล้ว] เนื้อหาคือคะแนนของโครงการ Skilled Nursing Facility Value-Based Purchasing ซึ่งวัดสี่ด้าน

ตัวชี้วัด	ความหมายทางธุรกิจ
อัตราการกลับเข้าโรงพยาบาล	ผู้ป่วยที่ต้องกลับเข้าโรงพยาบาลหลังจากออกจากสถานดูแล
อัตราการติดเชื้อในสถานพยาบาล	ตัวชี้วัดคุณภาพการควบคุมการติดเชื้อ
อัตราการลาออกของพยาบาล	เชื่อมกับ M4 โดยตรง ยืนยันว่า CMS เองก็ถือว่านี่คือคุณภาพ
ชั่วโมงพยาบาลปรับตามความหนักของผู้ป่วย	เชื่อมกับ M3
ตัวคูณเงินจูงใจ	ผลลัพธ์สุดท้าย: ตัวคูณที่ใช้กับเงินที่ CMS จ่ายให้จริง

ตารางที่ 7: สี่ตัวชี้วัดของโครงการ VBP และผลลัพธ์ที่เป็นตัวเงิน คอลัมน์สุดท้ายคือสิ่งที่ทำให้แหล่งนี้มีค่าต่อ CFO เพราะเป็นจุดเดียวในข้อมูลทั้งหมดที่แปลงคุณภาพเป็นรายได้ได้โดยตรง

8.2 ใช้ทำอะไร

เชื่อมเข้ากับ Fact_Facility_Monthly ด้วย CCN แล้วเพิ่มมิติ “ผลตอบแทน” ให้กับคำถาม BQ2 และ BQ3 — เปลี่ยนคำถามจาก “ลงทุนพนักงานแล้วคะแนนดีขึ้นไหม” เป็น “ลงทุนพนักงานแล้ว ได้เงินคืน เท่าไร” ซึ่งเป็นคำถามที่ CFO สนใจจริง

การเชื่อมข้าม Grain ต้องระวังการนับซ้ำ

VBP มีหนึ่งแถวต่อสถานที่ต่อ ปีงบประมาณ แต่ Fact 1 มีหลายแถวต่อสถานที่ต่อปี ถ้า JOIN ตรง ๆ ค่าตัวคูณเงินจูงใจจะถูกทำซ้ำในทุกงวด และการ SUM จะได้ค่าเกินจริงหลายเท่า

วิธีจัดการ: เก็บตัวคุณไว้เป็น แอตทริบิวต์ระดับปี แล้วใช้เฉพาะกับการรวมค่า ที่ระดับปีเท่านั้น ห้ามให้มันไหลลงไปที่ระดับงวด

9 แหล่งเสริมอีกสองแหล่ง

9.1 S4 — ประชากรอายุ 65 ปีขึ้นไป รายรัฐ

มาจาก U.S. Census Bureau American Community Survey ผ่าน API ที่คืน nested JSON ใช้เป็น **ฝั่งอุปสงค์** ของตลาด ซึ่งข้อมูล CMS ทั้งหมดไม่มีให้ เพราะ CMS มองแต่ฝั่งผู้ให้บริการ

การคำนวณไม่ตรงไปตรงมา: ตาราง B01001 แยกประชากรตามเพศและช่วงอายุย่อย จึงต้องรวมตัวแปรหลายตัว (ชาย 65–66, 67–69, 70–74, ... และหญิงชุดเดียวกัน) เข้าด้วยกันเองจึงจะได้ “ประชากร 65+”

แหล่งนี้ยังเรียกไม่สำเร็จ

[ยังไม่ตรวจ] การเรียก API รอบแรกคืนค่าว่าง ยังไม่ทราบสาเหตุ — อาจเป็นเรื่องคีย์ รูปแบบพารามิเตอร์ หรือปีที่ระบุไม่มีข้อมูล ต้องแก้ให้ได้ก่อนเริ่ม BQ1 ถ้าแก้ไม่ได้ ให้ใช้ทางถอยที่ระบุไว้ในกล่องส้มของหัวข้อ 3

9.2 S5 — ตาราง lookup ของ CMS

NH_CitationDescriptions (643 แถว) แปล รหัส ข้อ บกพร่อง เป็น คำ อธิบาย และ หมวด หมู่ ส่วน NH_StateUSAverages (54 แถว × 51 คอลัมน์) ให้ค่าเฉลี่ยรายรัฐและ ระดับประเทศ ใช้เป็น **เส้นอ้างอิง** บนกราฟ เพื่อให้ผู้อ่านรู้ว่าค่าที่เห็นดีหรือแย่กว่ามาตรฐาน

10 ตารางสืบย้อน — แหล่งไหนตอบคำถามไหน

ตารางนี้คือคำตอบรวบยอดของคำถาม “ข้อมูลมาจากไหน มีอะไร ใช้ทำอะไร” และเป็นสิ่งที่ควรคัดลอกไปใส่รายงานฉบับส่งโดยตรง

#	แหล่ง	รูปแบบ	ให้ข้อมูลอะไร	ป้อนตารางใด	ตอบข้อใด
S1	CMS Archived Snapshots	ZIP หลายไฟล์ หลายช่วงเวลา	โปรไฟล์ คะแนน ชั่วโมง พยาบาล ค่าปรับ ย้อน หลัง 7 ปี	Fact 1, Fact 2, Dim ทั้งหมด	BQ1–BQ8
S2	CMS Provider Data API	JSON ผ่าน HTTP	รายการ snapshot และ แถวข้อมูลปัจจุบัน	ไม่ป้อนตารางโดยตรง แต่ใช้ ETL และใช้ตรวจสอบ	ทุกข้อ (ทาง อ้อม)
S3	SNF VBP Facility Performance	CSV ราย ปีงบประมาณ	ตัวคุณเงินจูงใจและ คะแนนสี่ด้าน	แอตทริบิวต์ระดับปีของ Fact 1	BQ2, BQ3
S4	Census ACS API	Nested JSON	ประชากรอายุ 65+ รายรัฐ	Dim_Geography	BQ1
S5	CMS lookup tables	CSV เล็ก	คำอธิบายรหัส และค่า เฉลี่ยอ้างอิง	ตาราง lookup และเส้น อ้างอิงบนกราฟ	BQ1, BQ5, BQ7

ตารางที่ 8: ตารางสืบย้อนแหล่งข้อมูล อ่านจากซ้ายไปขวาจะได้ประโยคเต็มว่า แหล่งนี้มาจากไหน หน้าตาอย่างไร ให้อะไร ไปอยู่ตรงไหน และตอบคำถามข้อใด ทุกคำถามธุรกิจมีแหล่งรองรับครบ

ภาคที่ 3

คุณภาพข้อมูล — อะไรบ้าง

ภาคนี้ตอบคำถามว่า: ข้อมูลเปิดของรัฐบาลสะอาดพอจะใช้เลยไหม (คำตอบคือไม่)

โจทย์กำหนดให้มีปัญหาคุณภาพข้อมูลอย่างน้อย 3 ประเภท เอกสารนี้ระบุไว้ 8 ประเภท ทุกข้อมีทั้งวิธีตรวจจับ และวิธีแก้ไขจนแล้ววงหน้า เพื่อให้ขึ้น Clean ทำงานอัตโนมัติได้จริง

11 ปัญหาแปดประเภทและวิธีรับมือ

#	ประเภท	ปัญหาที่คาดว่าจะเจอ	วิธีตรวจจับและแก้
Q1	คีย์ไม่ตรงกัน	CCN เป็นรหัส 6 หลักที่มีศูนย์นำหน้า เช่น 015009 [ตรวจแล้ว] ถ้าอ่านเป็นตัวเลขจะเหลือ 15009 แล้วเชื่อมตารางไม่ได้	บังคับอ่านเป็นข้อความทุกไฟล์ แล้วเติมศูนย์ให้ครบ 6 หลัก ตรวจด้วยเงื่อนไขว่าอัตราการเชื่อมต่อสำเร็จต้องเกิน 99% ก่อนโหลดเข้าคลัง
Q2	ระเบียนซ้ำ	สถานที่เดียวกันปรากฏใน ทุก snapshot และค่าปรับรายการเดิม ถูกรายงานซ้ำข้ามหลาย snapshot	Fact 1 ตั้งใจให้ซ้ำ (เป็นสถานะรายงวด) จึงใส่ snapshot ไว้ในคีย์หลัก ส่วน Fact 2 ต้องกำจัดซ้ำจริง ด้วยคีย์ (ccn, วันที่, ประเภท, fine_id)
Q3	ค่าว่าง	คะแนนดาวว่างสำหรับสถานที่เปิดใหม่ และ CMS ใช้คอลัมน์ footnote คู่กัน เพื่อบอกเหตุผลที่ค่าถูกระงับ (มีอย่างน้อย 9 คอลัมน์) [ตรวจแล้ว]	ไม่เติมค่าเดา แต่เก็บรหัส footnote ไว้ แล้วกันแถวที่ถูกระงับออกจากตัวหาร ตอนคำนวณค่าเฉลี่ย
Q4	ค่าที่เป็นไปไม่ได้	ผู้พักอาศัยเฉลี่ยมากกว่าจำนวนเตียง ทำให้อัตราการเข้าพักเกิน 100% และอัตราลาออกที่เป็น 0% หรือเกิน 100%	เขียนกฎตรวจเป็นฟังก์ชัน: อัตราการเข้าพักต้องอยู่ใน [0, 1.2] อัตราลาออกต้องอยู่ใน (0, 200] แถวที่ตกกฎ ติดธง ไม่ลบทิ้ง
Q5	ชื่อหมวดไม่สอดคล้อง	ประเภทการถือครองมีหลายค่า เช่น For profit - Corporation [ตรวจแล้ว] คาดว่าสะกดต่างกันข้ามปี และชื่อเครื่องมือมีปัญหาตัวพิมพ์และช่องว่างเกิน	ทำตารางจับคู่แบบระบุชุด ไม่ใช้การเดาความคล้าย จากคำดิบไปเป็นกลุ่มการถือครอง 3 กลุ่ม ส่วนชื่อเครื่องมือให้ตัดช่องว่างและปรับตัวพิมพ์
Q6	รูปแบบวันที่ต่างกัน	วันที่กำหนดโทษและวันที่ตรวจ คาดว่าเปลี่ยนรูปแบบระหว่างปี 2562–2569 [ยังไม่ตรวจ]	แปลงด้วยรายการรูปแบบที่ระบุชุดเรียงลำดับลง ถ้าไม่เข้าเลยให้บันทึกไว้ ห้ามปล่อยให้เดารูปแบบเอง เพราะสลับวันกับเดือนได้เสียบบ่อย ๆ
Q7	โครงสร้างคอลัมน์เปลี่ยน	ปัจจุบันมี 99 คอลัมน์ [ตรวจแล้ว] แต่คอลัมน์อัตราลาออกและชั่วโมงช่วงสุดสัปดาห์เพิ่งถูกเพิ่มภายหลัง คาดว่า snapshot ปี 2562 ยังไม่มี [ยังไม่ตรวจ]	ทำตารางจับคู่ชื่อคอลัมน์แยกตามรุ่นของไฟล์ คอลัมน์ที่ยังไม่มีให้เป็นค่าว่าง และบันทึกตารางบันทึกการทำงานว่างวดใดขาดคอลัมน์ใด
Q8	หน่วยวัดไม่ตรงกัน	อัตราลาออกอาจถูกเก็บเป็นสัดส่วน (0.52) ในบางปี และเป็นเปอร์เซ็นต์ (52.0) ในบางปี [ยังไม่ตรวจ]	ตรวจจากคำนิยามฐานของแต่ละงวด ถ้าน้อยกว่า 1.5 ให้คูณ 100 แล้วบันทึกการแปลงลงตารางบันทึกการทำงาน

ตารางที่ 9: ปัญหาคุณภาพข้อมูลแปดประเภท ครอบคลุมทุกหัวข้อที่โจทย์ยกตัวอย่างไว้ คอลัมน์ขวาสุดเขียนเป็นภาษาที่แปลงเป็นโค้ดได้ทันที ซึ่งเป็นเจตนา — แผนที่แปลงเป็นโค้ดไม่ได้ คือแผนที่ยังคิดไม่จบ

อย่าอ่าน CCN เป็นตัวเลข แม้แต่ครั้งเดียว

015009 เป็นรหัสประจำสถานพยาบาล ไม่ใช่จำนวน การอ่านเป็นตัวเลขทำให้กลายเป็น 15009 ซึ่งจะเชื่อมกับตารางอื่นไม่ติดแบบเสียบบ่อย ๆ — ไม่มี error มีแต่แถวที่หายไปจากผลลัพธ์

รหัสไปรษณีย์ก็เป็นแบบเดียวกัน (01234 ในรัฐทางตะวันออกเฉียงเหนือ) กฎที่ปลอดภัยคือ อ่านทุกคอลัมน์เป็นข้อความก่อนเสมอ แล้วค่อยแปลงเฉพาะคอลัมน์ที่เป็นตัวเลขจริง

ติดธง ดีกว่าลบทิ้ง

ทุกกฎในตารางข้างบนที่เจอค่าผิดปกติ จะ **ติดธง is_suspect** ไว้ที่แถวนั้น ไม่ใช่ลบแถวทิ้ง เหตุผลสองข้อ
หนึ่ง — ค่าผิดปกติบางตัวคือของจริง เช่น อัตราการเข้าพัก 105% เกิดได้จริงเมื่อมีเตียงเสริมชั่วคราว
สอง — แดชบอร์ดจะมีสวิตช์ให้ผู้ใช้เลือกเองว่าจะรวมหรือไม่รวมแถวที่น่าสงสัย ซึ่งกลายเป็นตัวกรองที่
หนึ่งในห้าตัวไปในตัว และทำให้ผู้ใช้เห็นว่าข้อมูลไม่สมบูรณ์แบบ แทนที่จะซ่อนไว้

ภาคที่ 4

คลังข้อมูล — Grain และ Star Schema

ภาคนี้ตอบคำถามว่า: หนึ่งแถวในตาราง Fact หมายความว่าอะไรกันแน่

12 สี่ขั้นตอนของ Kimball

การออกแบบเดินตามลำดับสี่ขั้นตอนมาตรฐาน ห้ามข้ามลำดับ เพราะขั้นหลังพึ่งขั้นก่อนหน้าทั้งหมด

12.1 ขั้นที่ 1 — เลือกกระบวนการทางธุรกิจ

เลือก สองกระบวนการ เพราะทั้งคู่เป็นหัวใจของคำถาม และมี Grain ต่างกัน จึงต้องแยกตาราง Fact (ซึ่งโจทย์ระบุว่าได้คะแนนพิเศษ)

1. การติดตามผลการดำเนินงานรายงวด — CMS “ถ่ายรูป” สถานะของทุกแห่งทุกเดือน ไม่ใช่ธุรกรรม แต่เป็นสถานะ ณ เวลาหนึ่ง
2. การถูกลงโทษทางกฎระเบียบ — เกิดเป็นครั้ง ๆ มีวันที่ชัดเจนและมีมูลค่าเป็นเงิน

13 ขั้นที่ 2 — ประกาศ Grain


Grain คือประโยคเดียวที่ต้องเขียนให้ได้ก่อนทำอย่างอื่น

Grain คือคำตอบของคำถาม “หนึ่งแถวในตารางนี้แทนอะไรในโลกจริง” ถ้าตอบเป็นประโยคเดียวไม่ได้ แปลว่ายังออกแบบไม่เสร็จ และทุกอย่างที่สร้างต่อจากนั้นจะพังตามมา

ตาราง Fact	หนึ่งแถวหมายถึงอะไร	ประเภทและเหตุผล
Fact_Facility_Monthly	หนึ่งแถว = สถานพยาบาลหนึ่งแห่ง (หนึ่ง CCN) ณ วันที่ CMS เผยแพร่ข้อมูลหนึ่งครั้ง ตัวอย่าง: “CCN 015009 ตามข้อมูลที่เผยแพร่วันที่ 24 มิ.ย. 2569”	Periodic Snapshot — บันทึกสถานะ ไม่ใช่เหตุการณ์ แถวถูกสร้างทุกงวดแม้ไม่มีอะไรเปลี่ยน ซึ่งเป็นสิ่งที่ต้องการ เพราะทำให้เส้นกราฟต่อเนื่องไม่ขาด
Fact_Penalty_Event	หนึ่งแถว = บทลงโทษหนึ่งรายการ (ค่าปรับหนึ่งครั้ง หรือการระงับการจ่ายเงินหนึ่งครั้ง) ที่ CMS ส่งกับสถานพยาบาลหนึ่งแห่ง ในวันที่กำหนดโทษหนึ่งวัน ตัวอย่าง: “ค่าปรับ 12,350 ดอลลาร์ กับ CCN 015009 วันที่ 3 มี.ค. 2568”	Transaction — เป็นเหตุการณ์จริง ณ จุดเวลา ไม่มีแถวถ้าไม่มีเหตุการณ์ ทำให้การรวมยอดค่าปรับเป็นการบวกที่ถูกต้องแท้จริง

ตารางที่ 10: การประกาศ Grain ของทั้งสองตาราง Fact ประโยชน์ตัวหนาคือสิ่งที่ต้องท่องได้ ส่วนตัวอย่างข้างใต้มีไว้เพื่อให้เห็นภาพว่าแถวจริงหน้าตาเป็นอย่างไร

13.1 ทำไมสองตารางนี้ถึงรวมกันไม่ได้



นี่คือเหตุผลที่ต้องแยกเป็นสองตาราง

ถ้ายึดไว้ตารางเดียว งวดที่ไม่มีค่าปรับจะต้องใส่ศูนย์ และงวดที่มีค่าปรับสองครั้งจะต้องทำสำเนาแถวสถานะขึ้นมาสองแถว ทำให้ข้อมูลโรงพยาบาลและจำนวนเตียงถูกนับซ้ำทันที

รูปที่ 4: Grain ที่ต่างกันของสอง Fact เมื่อวางบนแกนเวลาเดียวกัน แถบน้ำเงินเกิดสมำเสมอตามงวดที่ CMS เผยแพร่ ส่วนแถบส้มเกิดกระจายตามเหตุการณ์จริง สองจังหวะนี้อยู่ในตารางเดียวกันไม่ได้

ProviderInfo มีคอลัมน์ค่าปรับอยู่แล้ว แต่ใช้แทน Fact 2 ไม่ได้

คอลัมน์ Total Amount of Fines in Dollars ใน ProviderInfo เป็น ยอดสะสมย้อนหลังรวมสามปี [ยังไม่ตรวจ] (ต้องยืนยันกับคู่มือ)

ถ้าเป็นเช่นนั้นจริง มันรวมข้ามสถานที่ได้ แต่ รวมข้ามงวดไม่ได้ เพราะจะนับซ้ำ คำถาม BQ7 ที่ถามว่า “ค่าปรับกระจุกในช่วงเวลาใด” จึงตอบจากคอลัมน์นี้ไม่ได้เลย — นี่คือเหตุผลเชิงออกแบบของ Fact 2 ไม่ใช้การเพิ่มตารางเพื่อเอาคะแนนพิเศษ

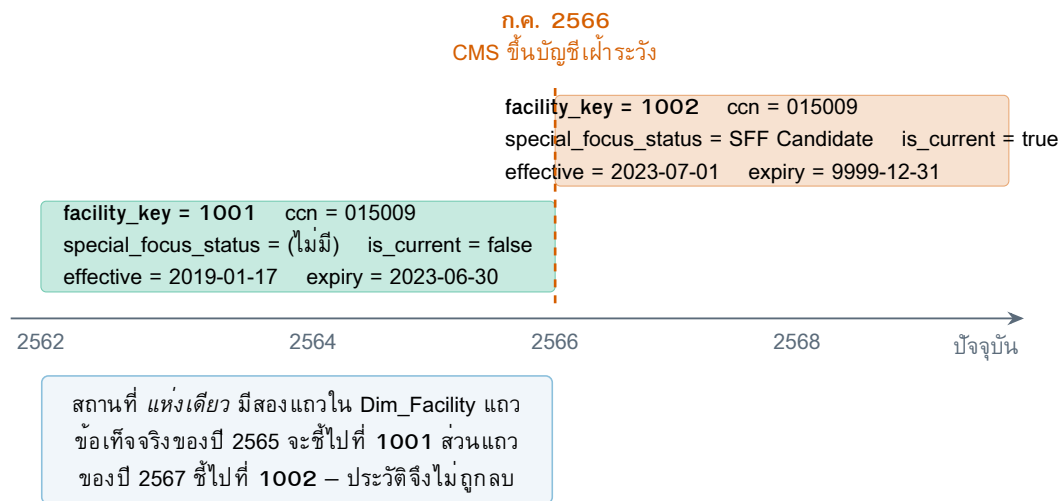
14 ขั้นที่ 3 — เลือก Dimensions

ได้ **หกดตาราง** เกินเกณฑ์ขั้นต่ำตาราง โดยหัวตัวแรกเป็น *Conformed Dimension* ที่ใช้ร่วมกันทั้งสอง Fact ซึ่งเป็นสิ่งที่ทำให้ถามข้ามตารางได้ เช่น “ค่าปรับเฉลี่ยต่อเตียง เทียบกับ คະแนนดาวเฉลี่ย ในรัฐเดียวกัน”

Dimension	ชนิด	ใช้กับ	เหตุผล
Dim_Date	—	ทั้งสอง	โจทย์บังคับให้มี ทำที่ระดับวันเพื่อรองรับ Fact 2 และใช้ได้หลายบทบาท: วันเผยแพร่ วันกำหนดโทษ วันตรวจ วันรับรองครั้งแรก
Dim_Facility	SCD ชนิดที่ 2	ทั้งสอง	ต้องเป็นชนิดที่ 2 เพราะสถานะ Special Focus และไอคอนการทารุณกรรม <i>เปลี่ยนไปตามเวลา</i> ถ้าเขียนทับจะตอบ BQ6 ไม่ได้ว่าเคยติดธงแดงหรือไม่
Dim_Geography	ชนิดที่ 1	ทั้งสอง	รวมรหัสไปรษณีย์ เมือง เคาน์ตี รัฐ ภูมิภาค ไว้ตารางเดียว เป็น star ไม่ใช่ snowflake และเป็นจุดเชื่อมกับข้อมูลประชากร
Dim_Ownership	ชนิดที่ 1	ทั้งสอง	แยกออกมาเพราะ BQ2 ต้องการแบ่งกลุ่มด้วยรูปแบบการถือครองโดยตรง และค่าดิบมีหลายค่าที่ต้องยุบเหลือสามกลุ่ม
Dim_Chain	ชนิดที่ 1	ทั้งสอง	รองรับ BQ8 เก็บรหัสเครือ ขนาดเครือ และธงว่าเป็นอิสระหรือไม่
Dim_Penalty_Type	ชนิดที่ 1	Fact 2	แยก “ค่าปรับเป็นเงิน” ออกจาก “ระงับการจ่ายเงิน” ซึ่งมีนัยทางการเงินต่างกันมาก

ตารางที่ 11: หก Dimension และเหตุผลที่ต้องมีแต่ละตัว ตัวที่ต้องระวังที่สุดคือ Dim_Facility เพราะเป็นชนิดที่ 2 ตัวเดียวในผัง

14.1 SCD ชนิดที่ 2 ทำงานอย่างไร




รูปที่ 5: การทำงานของ SCD ชนิดที่ 2 บน Dim_Facility เมื่อสถานะเผื่อระวังเปลี่ยน ระบบสร้างแถวใหม่แทนการเขียนทับ ทำให้คำถามอย่าง คะแนนตกหลังติดบัญชีเผื่อระวังหรือไม่ ตอบได้

ผลข้างเคียงของ SCD ชนิดที่ 2 ที่ลืมนับน้อย

เมื่อ facility_key ไม่ใช่หนึ่งต่อหนึ่งกับ CCN อีกต่อไป การเชื่อมตารางด้วย CCN เฉย ๆ จะได้แถวเกินมาเป็นทวีคูณ

ต้องเลือกเวอร์ชันที่ตรงช่วงเวลาเสมอ นั่นคือ $\text{effective_date} \leq \text{วันที่ของข้อเท็จจริง} < \text{expiry_date}$ กฎข้อนี้ต้องเขียนไว้ในโค้ด ETL เป็นฟังก์ชันเดียวที่ทุกที่เรียกใช้ ไม่ใช่เขียนเงื่อนไขซ้ำในทุก query

15 ชั้นที่ 4 — ผัง Star Schema



รูปที่ 6: ผัง Star Schema สองตาราง Fact และหก Dimension เส้นทึบเขียวคือความสัมพันธ์หลัก เส้นประน้ำเงินคือ conformed dimension ที่ใช้ร่วมกันทั้งสอง Fact — PK คือคีย์หลัก FK คือคีย์นอก DD คือ degenerate dimension ที่เก็บรหัสจากระบบต้นทางไว้ในตาราง Fact เอง

ผัง Star Schema ที่มีสอง Fact มักถูกวาดกว้าง จนต้องหมุนหน้ากระดาษเป็นแนวนอน เอกสารนี้เลียงด้วยการ วาด Fact ซ้อนกันแนวตั้ง แล้ววาด Dimension ที่ใช้ร่วมกันไว้สองข้าง ผังจึงสูงกว่ากว้างและพอดีหน้า A4 แนวตั้ง และได้ผลพลอยได้คือ ดูออกทันทีว่า Dimension ตัวใดใช้ร่วมกัน — ตัวที่มีเส้นออกทั้งขึ้นและลง

16 ข้อควรระวังของผังนี้

1. Dim_Date ต้องย้อนไปไกลกว่าที่คิด — คอลัมน์วันที่ได้รับรองครั้งแรก อาจย้อนไปถึงทศวรรษ 2500 จึงสร้างช่วง 1960-01-01 ถึง 2027-12-31 (ราว 24,800 แถว ซึ่งเล็กมาก) พร้อมแถวพิเศษ date_key = -1 สำหรับค่าที่ไม่ทราบ
2. ccn ถูกเก็บเป็น degenerate dimension ในทั้งสอง Fact — เพื่อให้ตรวจสอบย้อนกลับ ไปยังไฟล์ดิบได้โดยไม่ต้องเชื่อมตาราง และทำให้ตรวจสอบการจัดข้อมูลง่ายขึ้น
3. ค่าเฉลี่ยของเครื่องจะไม่เก็บใน Dim_Chain — เพราะ CMS คำนวณใหม่ทุกเดือน ถ้าเก็บไว้ในตาราง Dimension แบบเขียนทับ กราฟย้อนหลังจะใช้ค่าปัจจุบันทั้งหมดและผิด จะคำนวณจากตาราง Fact ตอนสอบถามแทน
4. is_suspect ติดอยู่กับแถว Fact ไม่ใช่ Dimension — เพราะเป็นคุณสมบัติของ การวัดครั้งนั้น ไม่ใช่ของสถานที่

ภาคที่ 5

ETL และ Dashboard — แผนงานถัดไป

ภาคนี้ตอบคำถามว่า: ขั้นตอนต่อไปต้องสร้างอะไรบ้าง (ยังไม่ได้เริ่ม)

17 กระบวนการ ETL ห้าขั้น

ขั้น	สิ่งที่ทำ
Extract	เรียก API ปลายทาง A เพื่อได้รายการ snapshot ทั้งหมด เลือกเฉพาะรายไตรมาส ดาวน์โหลด ZIP โดยข้ามไฟล์ที่มีอยู่แล้ว แล้วคลายเฉพาะ 6 CSV ที่ใช้จริง
Clean	ใช้กฎ Q1-Q8 จากภาค 3 ทุกกฎเขียนเป็นฟังก์ชันแยก และเขียนผลลงตารางบันทึกการทำงาน ว่างวดใดแก้อะไรไปกี่แถว
Transform	สร้าง surrogate key สร้าง Dim_Date ทำ SCD ชนิดที่ 2 ให้ Dim_Facility และคำนวณ measure ที่หาได้จากตัวอื่น
Integrate	เชื่อม CMS กับ VBP กับข้อมูลประชากร ด้วย CCN และรหัสรัฐ พร้อมรายงานอัตราการเชื่อมต่อสำเร็จ
Load	เขียนลงฐานข้อมูลไฟล์เดียว แล้วรันการตรวจสอบหลังโหลด: คีย์นอกครบทุกตัว ไม่มีคีย์หลักซ้ำ และจำนวนแถวตรงกับที่ตั้งมา

ตารางที่ 12: ห้าขั้นของ ETL ตามที่โจทย์กำหนด หลักการที่ยึดคือรันซ้ำได้โดยไม่ต้องแก้มือ และรันซ้ำแล้วต้องได้ผลเหมือนเดิม

18 แผนแดชบอร์ด

โจทย์กำหนด: measure สรุปลงอย่างน้อย 3 ตัว กราฟอย่างน้อย 5 กราฟ กราฟตามช่วงเวลาอย่างน้อย 1 กราฟ เปรียบเทียบอย่างน้อย 1 ตัวกรองอย่างน้อย 2 และข้อเสนอแนะอย่างน้อย 5 ข้อ

#	กราฟ	ชนิด	ตอบข้อใด
C1	การ์ดสรุป: อัตราการเข้าพัก คะแนนเฉลี่ย ค่าปรับรวม ชั่วโมงพยาบาล	ตัวเลขสรุป	ภาพรวม
C2	อัตราการเข้าพักและคะแนนเฉลี่ยรายไตรมาส 2562-2569	เส้น (ตามช่วงเวลา)	BQ5
C3	เปรียบเทียบคุณภาพและค่าปรับตามรูปแบบการถือครอง	แท่งกลุ่ม (เปรียบเทียบ)	BQ2
C4	ชั่วโมงพยาบาล เทียบกับ คะแนนดาว (จุดละหนึ่งแห่ง)	กระจาย + เส้นแนวโน้ม	BQ3
C5	เตียงต่อผู้สูงอายุพันคน รายรัฐ	แผนที่หรือแท่งเรียง	BQ1
C6	มูลค่าค่าปรับรายไตรมาส แยกตามประเภทบทลงโทษ	แท่งซ้อน	BQ7
C7	ตารางเผื่อระวัง: สถานที่ที่คะแนนลดต่อเนื่อง	ตาราง + แถบสี	BQ6
C8	อัตราลาออก เทียบกับ คะแนน แบ่งตามขนาดเครือ	กล่อง	BQ4, BQ8

ตารางที่ 13: แปรกราฟและคำถามที่แต่ละกราฟตอบ ไม่มีกราฟใดที่ไม่ผูกกับคำถามธุรกิจ ซึ่งเป็นข้อกำหนดของโจทยโดยตรง

ตัวกรองหัวข้อ: ช่วงเวลา · รัฐ · รูปแบบการถือครอง · ขนาดเครือ · สวิตช์รวมหรือไม่รวมแถวที่ติดธง is_suspect

19 คะแนนพิเศษที่ตั้งเป้า

1. สองตาราง Fact — โจทย์ระบุว่าได้คะแนนพิเศษโดยตรง และมีเหตุผลเชิงออกแบบรองรับ
2. การใช้ API — ปลายทาง JSON ของ CMS [\[ตรวจสอบแล้ว\]](#)
3. ไปป์ไลน์อัตโนมัติและการโหลดแบบเพิ่มเติม — ข้าม snapshot ที่โหลดแล้ว
4. การตรวจคุณภาพข้อมูลอัตโนมัติ — กฎ Q1-Q8 พร้อมตารางบันทึกการทำงาน
5. แดชบอร์ดด้วยเครื่องมือสมัยใหม่ — Streamlit บนฐานข้อมูล DuckDB
6. ชุดข้อมูลสำหรับต่อยอดการพยากรณ์ — ตารางแบนสำหรับทำนายว่า สถานที่ใดจะถูกปรับในไตรมาสถัดไป

20 สิ่งที่ต้องทำก่อนเริ่มพัฒนา

1. ยืนยันกับ NH_Data_Dictionary.pdf ว่ายอดค่าปรับใน ProviderInfo เป็นยอดสะสมกี่ปี — มีผลต่อเหตุผลของ Fact 2 โดยตรง
2. เปิด snapshot ปี 2562 เทียบคอลัมน์กับปี 2569 เพื่อยืนยันข้อ Q7
3. หาสาเหตุที่ Census API ไม่คืนค่า และเตรียมทางถอยสำหรับ BQ1
4. ตรวจสอบว่ารหัส Fine ID ไม่ซ้ำข้าม snapshot จริงหรือไม่ เพราะเป็นภัยของการกำจัดข้อมูลซ้ำใน Fact 2

5. เติมหมายเลขกลุ่มและชื่อสมาชิกสามคนลงหน้าปก

ภาคผนวก

A อภิธานศัพท์ ไทย-อังกฤษ

ไทย	อังกฤษ	ความหมายย่อ
คลังข้อมูล	data warehouse	ฐานข้อมูลที่จัดโครงสร้างไว้เพื่อการวิเคราะห์ ไม่ใช่เพื่อรับรายการ
ความละเอียดของข้อมูล	grain	หนึ่งแถวในตาราง Fact แทนอะไรในโลกจริง
ตารางข้อเท็จจริง	fact table	ตารางกลางที่เก็บตัวเลขที่ต้องการวัด
ตารางมิติ	dimension table	ตารางรอบข้างที่บอกว่าตัวเลขนั้นเป็นของใคร ที่ไหน เมื่อไร
มิติร่วม	conformed dimension	ตารางมิติที่ใช้ร่วมกันได้หลายตาราง Fact
มิติเสื่อม	degenerate dimension	รหัสจากระบบต้นทางที่เก็บไว้ในตาราง Fact เอง
คีย์แทน	surrogate key	คีย์ที่ระบบสร้างเอง ไม่ใช่รหัสจากต้นทาง
มิติที่เปลี่ยนช้า ชนิดที่ 2	slowly changing dimension type 2	เก็บประวัติด้วยการเพิ่มแถวใหม่ ไม่เขียนทับ
สถานะรายงวด	periodic snapshot	ตาราง Fact ที่บันทึกสถานะทุกงวด แม้ไม่มีการเปลี่ยนแปลง
ธุรกรรม	transaction fact	ตาราง Fact ที่มีแถวเฉพาะเมื่อเกิดเหตุการณ์
การรวมค่าได้	additivity	บอกว่า measure นั้นเอาไปบวกกันตรง ๆ ได้หรือไม่
อัตราการเข้าพัก	occupancy rate	ผู้พักอาศัยเฉลี่ยต่อวัน หาดด้วย จำนวนเตียงที่รับรอง
ชั่วโมงพยาบาลต่อคนต่อวัน	hours per resident day (HPRD)	ชั่วโมงงานพยาบาลทั้งหมด หาดด้วย จำนวนผู้พักอาศัย
อัตราการลาออก	turnover rate	สัดส่วนพนักงานที่ลาออกในรอบหนึ่งปี
การโหลดแบบเพิ่มเติม	incremental load	โหลดเฉพาะข้อมูลใหม่ ไม่โหลดซ้ำทั้งหมด
รหัสรับรองสถานพยาบาล	CMS Certification Number (CCN)	รหัสหลักประจำสถานพยาบาล มีศูนย์นำหน้าได้
สถานะเฝ้าระวังพิเศษ	Special Focus Facility (SFF)	สถานะที่ CMS ให้กับสถานที่ที่มีปัญหาคุณภาพซ้ำซาก
การจัดซื้อตามคุณค่า	value-based purchasing (VBP)	โครงการที่ผูกเงินที่จ่ายให้เข้ากับผลลัพธ์ด้านคุณภาพ

B คอลัมน์สำคัญของ NH_ProviderInfo ที่จะใช้จริง

จาก 99 คอลัมน์ โครงการนี้ใช้จริงราว 30 คอลัมน์ ที่เหลือเป็นเชิงอรรถและรายละเอียด การตรวจรายรอบที่ไม่ได้ใช้

คอลัมน์ต้นทาง	ไปเป็นอะไร	หมายเหตุ
CMS Certification Number (CCN)	ศัพทมูลวิทยา	ต้องอ่านเป็นข้อความ (ดูกฎ Q1)
Provider Name, Legal Business Name	Dim_Facility	เปลี่ยนได้เมื่อเปลี่ยนเจ้าของ
City/Town, State, ZIP Code, County/Parish, Urban	Dim_Geography	
Latitude, Longitude	Dim_Geography	ใช้ทำแผนที่
Ownership Type	Dim_Ownership	ต้องยุบเหลือสามกลุ่ม (กฎ Q5)
Chain Name, Chain ID, Number of Facilities in Chain	Dim_Chain	
Special Focus Status, Abuse Icon	Dim_Facility (SCD2)	เหตุผลที่ต้องใช้ชนิดที่ 2
Number of Certified Beds	measure	ตัวหารของอัตราการเข้าพัก
Average Number of Residents per Day	measure	ตัวตั้งของอัตราการเข้าพัก
Reported Total Nurse Staffing HPRD	measure M3	
Reported RN Staffing HPRD	measure	แยกดูสัดส่วนพยาบาลวิชาชีพ
Total Nursing Staff Turnover	measure M4	ระวางหน่วยวัด (กฎ Q8)
Overall Rating และคะแนนย่อยอีก 3 ตัว	measure M7	มีคอลัมน์ footnote คู่กัน
Rating Cycle 1 Total Number of Health Deficiencies	measure M8	
Total Amount of Fines in Dollars	ไม่ใช่	เป็นยอดสะสม ใช้ Fact 2 แทน
Processing Date	snapshot_date_key	วันที่ของ Grain

ตารางที่ 15: การจับคู่คอลัมน์ต้นทางกับปลายทาง แฉสุดท้ายที่ระบุว่าไม่ใช่ คือการตัดสินใจที่สำคัญที่สุดในตารางนี้ และเป็นเหตุผลที่มีตาราง Fact ที่สอง

C คำสั่งที่ใช้ตรวจสอบตัวเลขในเอกสารนี้

ตัวเลขทุกตัวที่กำกับ **[ตรวจแล้ว]** มาจากการรันคำสั่งเหล่านี้จริง ถ้า CMS ออกข้อมูลใหม่ แล้วรันซ้ำได้ผลต่างไป ตัวเลขในเนื้อหาต้องแก้ตาม

1. รายการ snapshot ทั้งหมด

```
curl -sS "https://data.cms.gov/provider-data/api/1/archive/aggregate/theme/nursing-homes/relative"
```

2. ดาวน์โหลดและดูรายชื่อไฟล์ใน snapshot

```
curl -sS -o nh.zip "https://data.cms.gov/provider-data/sites/"
```



```
default/files/dataset-archives/theme/nursing-homes/
nursing-homes_2026-06-24.zip" && unzip -l nh.zip
```

3. นั้บ แถว และ คอลัมน์ ของ CSV — คลาย ZIP แล้ว อ่าน ด้วย pandas โดย กำหนด dtype=str และ encoding='latin-1' (ไฟล์ไม่ใช่ UTF-8 ล้วน)

4. ดึงแถวตัวอย่างจาก API

```
curl -sS "https://data.cms.gov/provider-data/api/1/datastore/
query/4pq5-n9py/0?limit=1"
```

D แหล่งอ้างอิง

แหล่ง	เกี่ยวข้องกับเอกสารนี้อย่างไร
CMS Provider Data Catalog — Nursing Homes data.cms.gov/provider-data	แหล่งข้อมูลหลักทั้งหมด ต้องอ้างอิงในรายงานฉบับส่งและในวิดีโอ
CMS Nursing Home Five-Star Quality Rating System — Technical Users' Guide	นิยามของคะแนนดาวและวิธีคำนวณ ต้องใช้ตอนอธิบายว่า M7 หมายถึงอะไร
NH_Data_Dictionary.pdf (อยู่ใน ZIP)	คำจำกัดความของทุกคอลัมน์ ต้องเปิดก่อนเริ่ม ETL เพื่อยืนยันข้อสงสัยเรื่องยอดสะสมของค่าปรับ
Kimball & Ross — The Data Warehouse Toolkit	ที่มาของสี่ขั้นตอนการออกแบบ และของคำว่า periodic snapshot กับ transaction fact ซึ่งเป็นแกนของภาค 4

เอกสารภายในโครงการที่ควรอ่านคู่กัน

- group project/69-1-Mini DW & Dashboard-1.pdf — โจทย์ต้นฉบับ พร้อมเกณฑ์ให้คะแนนทั้งหมด
- PROGRESS.md — บันทึกความคืบหน้าสะสมของทั้งรายวิชา

เอกสารนี้เป็นแผนการออกแบบก่อนลงมือพัฒนา รูปทุกรูปวาดด้วย TikZ ไม่ใช่ผลลัพธ์จากการรันจริง ตัวเลขขนาดข้อมูลทุกตัวที่กำกับ **[ตรวจแล้ว]** ตรวจสอบซ้ำได้ด้วยคำสั่งในภาคผนวก ค ส่วนที่กำกับ **[ยังไม่ตรวจ]** ยังเป็นสมมติฐาน ห้ามนำไปอ้างในรายงานฉบับส่งจนกว่าจะพิสูจน์แล้ว