

# ElderCare Insight

คลังข้อมูลและแดชบอร์ดสำหรับธุรกิจสถานดูแลผู้สูงอายุ  
จากข้อมูลเปิดของ CMS สหรัฐอเมริกา ปี 2562–2569

เอกสารนี้เป็น **แผนการออกแบบระบบ** ก่อนลงมือพัฒนา ครอบคลุมตั้งแต่  
ปัญหาทางธุรกิจ คำถามที่ต้องตอบ แหล่งข้อมูลทั้งห้า แหล่งปัญหา  
คุณภาพข้อมูลที่ต้องรับมือ ไปจนถึงการประกาศ Grain และผัง Star  
Schema

รูปทูลูกบ่งในเอกสารนี้เป็นภาพอธิบายที่วาดขึ้นเอง **ยังไม่มีรูปผลลัพธ์จริง**  
เพราะยังไม่ได้รัน ETL ส่วนตัวเลขขนาดข้อมูลทุกตัวมาจากการเปิดไฟล์  
จริงแล้ว และตรวจซ้ำได้ด้วยคำสั่งในภาคผนวก ค

เอกสารนี้เป็น **เอกสารทำงาน** จึงยาวกว่ารายงานฉบับส่งที่โจทย์จำกัดไว้  
10–15 หน้า รายงานฉบับส่งจะย่อจากภาค 1–4 ของเอกสารนี้

## สารบัญ


|                                                     |    |
|-----------------------------------------------------|----|
| เอกสารนี้อ่านอย่างไร                                | 4  |
| 1 ธุรกิจและคำถาม — เราจะตอบอะไร                     | 6  |
| 1 ธุรกิจสถานดูแลผู้สูงอายุทำงานอย่างไร              | 6  |
| 1.1 ปัญหาทางธุรกิจที่ต้องการแก้ . . . . .           | 7  |
| 2 ใครใช้ข้อมูลนี้ (Stakeholders)                    | 8  |
| 3 คำถามทางธุรกิจแปดข้อ                              | 8  |
| 4 Measures และกับดักของการรวมค่า                    | 9  |
| 2 แหล่งข้อมูล — มาจากไหน มีอะไร ใช้ทำอะไร           | 11 |
| 5 ภาพรวมทั้งห้าแหล่ง                                | 11 |
| 6 แหล่งที่ 1 — CMS Nursing Homes Archived Snapshots | 11 |
| 6.1 มาจากไหน . . . . .                              | 11 |
| 6.2 มีอะไรอยู่ข้างใน . . . . .                      | 12 |
| 6.3 ใช้ทำอะไร . . . . .                             | 13 |
| 7 แหล่งที่ 2 — CMS Provider Data Catalog REST API   | 14 |
| 7.1 มาจากไหน . . . . .                              | 14 |
| 7.2 มีอะไร . . . . .                                | 14 |
| 7.3 ใช้ทำอะไร . . . . .                             | 15 |
| 8 แหล่งที่ 3 — SNF VBP Facility Performance         | 16 |
| 8.1 มาจากไหน มีอะไร . . . . .                       | 16 |
| 8.2 ใช้ทำอะไร . . . . .                             | 16 |
| 9 แหล่งเสริมอีกสองแหล่ง                             | 16 |
| 9.1 S4 — ประชากรอายุ 65 ปีขึ้นไป รายรัฐ . . . . .   | 16 |
| 9.2 S5 — ตาราง lookup ของ CMS . . . . .             | 17 |

|                                                    |    |
|----------------------------------------------------|----|
| 10 ตารางสืบย้อน — แหล่งไหนตอบคำถามไหน              | 17 |
| 3 คุณภาพข้อมูล — อะไรพังบ้าง                       | 19 |
| 11 ปัญหาแปดประเภทและวิธีรับมือ                     | 20 |
| 4 คลังข้อมูล — Grain และ Star Schema               | 22 |
| 12 สี่ขั้นตอนของ Kimball                           | 22 |
| 12.1 ขั้นที่ 1 — เลือกกระบวนการทางธุรกิจ . . . . . | 22 |
| 13 ขั้นที่ 2 — ประกาศ Grain                        | 22 |
| 13.1 ทำไมสองตารางนี้ถึงรวมกันไม่ได้ . . . . .      | 23 |
| 14 ขั้นที่ 3 — เลือก Dimensions                    | 24 |
| 14.1 SCD ชนิดที่ 2 ทำงานอย่างไร . . . . .          | 25 |
| 15 ขั้นที่ 4 — ผัง Star Schema                     | 26 |
| 16 ข้อควรระวังของผังนี้                            | 27 |
| 5 ETL และ Dashboard — แผนงานถัดไป                  | 28 |
| 17 กระบวนการ ETL ห้าขั้น                           | 28 |
| 18 แผนแดชบอร์ด                                     | 28 |
| 19 คะแนนพิเศษที่ตั้งเป้า                           | 29 |
| 20 สิ่งที่ต้องทำก่อนเริ่มพัฒนา                     | 29 |
| ภาคผนวก                                            | 31 |
| ภาคผนวก                                            | 31 |
| A อภิธานศัพท์ ไทย-อังกฤษ                           | 31 |
| B คอลัมน์สำคัญของ NH_ProviderInfo ที่จะใช้จริง     | 32 |

|                                        |    |
|----------------------------------------|----|
| C คำสั่งที่ใช้ตรวจสอบตัวเลขในเอกสารนี้ | 32 |
| D แหล่งอ้างอิง                         | 33 |

## เอกสารนี้อ่านอย่างไร

เอกสารแบ่งเป็นห้าภาค เรียงตามทางเดินของข้อมูลจริง ไม่ใช่เรียงตามหัวข้อทฤษฎี ผู้อ่านที่หลงทางสามารถถามตัวเองว่า “ตอนนี้ข้อมูลอยู่ตรงไหนของท่อ” แล้วจะรู้ทันทีว่าอยู่ภาคใด



รูปที่ 1: แผนที่ของเอกสาร ห้าภาคเรียงตามทางเดินของข้อมูล จากคำถามทางธุรกิจไปจนถึงหน้าจอที่ผู้บริหารเห็น

## ระบบที่ใช้ตลอดเอกสาร

สีสี่สีนี้แทน ระยะของไปป์ไลน์ และจะถูกใช้ความหมายเดิมทุกที่ ทั้งในเนื้อความ ในผัง และในกราฟของแดชบอร์ดภายหลัง ชุดสีเป็น Okabe-Ito ซึ่งปลอดภัยต่อผู้มีภาวะตาบอดสี

- **แหล่งข้อมูล** — ข้อมูลดิบจากภายนอกที่เรายังทำอะไรไม่ได้
- **ETL** — ขั้นตอนแปลงข้อมูล จุดที่ความผิดพลาดเกิดขึ้นมากที่สุด
- **คลังข้อมูล** — ตาราง Fact และ Dimension ที่ออกแบบเอง
- **Dashboard** — สิ่งที่ใช้เห็นและตัดสินใจจากมัน

## กล่องสีแบบ และความหมายของมัน

กล่องด้านล่างนี้ คือคำนิยามของตัวเอง — เนื้อหาในกล่องบอกว่ากล่องสีนั้นใช้เมื่อไร

### กล่องน้ำเงิน: ข้อสรุปที่ต้องจำ

ใช้กับใจความที่ร้อยหลายบทเข้าด้วยกัน ถ้าอ่านเอกสารนี้แบบเร็ว ให้อ่านเฉพาะกล่องน้ำเงิน

### กล่องส้ม: กับดัก หรือข้อแม้ที่ถ้าลืมแล้วข้อสรุปจะผิด

ใช้กับสมมติฐานที่เปราะ และกับจุดที่คนทำงาน DW พลาดกันบ่อย

### กล่องเขียว: สิ่งที่ต้องตรวจสอบกับข้อมูลจริงแล้ว

ใช้เฉพาะกับตัวเลขหรือข้อเท็จจริงที่เปิดไฟล์ดูจริงหรือเรียก API จริงแล้ว ไม่ใช่กับสิ่งที่คาดว่าจะเป็น

**กล่องแดง: วิธีที่ผิดจริง ๆ**

ใช้น้อยที่สุด — เฉพาะแนวทางที่ถ้าทำตามแล้วผลลัพธ์จะผิด ไม่ใช่แค่ไม่สวย

**สถานะของข้อมูลในเอกสารนี้**

ข้อความที่กำกับ **[ตรวจสอบแล้ว]** หมายถึงเปิดไฟล์จริงหรือเรียก API จริงแล้ว ส่วน **[ยังไม่ตรวจสอบ]** คือสมมติฐานที่ยังต้องพิสูจน์ในขั้น ETL — อย่าอ้างอิงข้อความกลุ่มหลัง ในรายงานฉบับส่งจนกว่าจะตรวจสอบแล้ว

## ภาคที่ 1

# ธุรกิจและคำถาม — เราจะตอบอะไร

ภาคนี้ตอบคำถามว่า: ก่อนแต่ละข้อมูลแม้แต่แถวเดียว เราต้องการรู้อะไรกันแน่

## 1 ธุรกิจสถานดูแลผู้สูงอายุทำงานอย่างไร

สถานดูแลผู้สูงอายุแบบ Skilled Nursing Facility (SNF) ในสหรัฐอเมริกา เป็นธุรกิจที่มีลักษณะเฉพาะสามอย่างพร้อมกัน

1. รายได้ผูกกับอัตราการเข้าพัก (occupancy) เพราะต้นทุนต่อเตียงเป็นต้นทุนคงที่ เพียงว่างหนึ่งเตียงคือรายได้ที่หายไปโดยที่ต้นทุนไม่ลด
2. ต้นทุนหลักคือค่าแรงพยาบาลและผู้ช่วยพยาบาล ซึ่งกินสัดส่วนต้นทุนดำเนินงานสูงสุด
3. ถูกกำกับเข้มโดยรัฐ ผ่านระบบให้คะแนน Five-Star Quality Rating การตรวจสอบสถานประกอบการ และบทลงโทษทางการเงิน

สิ่งที่ทำให้ธุรกิจนี้น่าสนใจในเชิงวิเคราะห์คือ ทั้งสามอย่างนี้ ไม่ได้แยกกัน แต่ป้อนกลับเข้าหากันเป็นวงจร



รูปที่ 2: วงจรป้อนกลับของธุรกิจสถานดูแลผู้สูงอายุ — คะแนนคุณภาพไม่ใช่แค่ตัวชี้วัด แต่เป็นตัวขับเคลื่อนรายได้ ระบบคลังข้อมูลนี้จึงต้องเชื่อมคุณภาพ ต้นทุนแรงงาน และค่าปรับไว้ในที่เดียวกัน

### ทำไมต้องสร้างคลังข้อมูลเอง ทั้งที่ CMS เปิดข้อมูลให้ดูอยู่แล้ว

เว็บของ CMS ให้ดูได้เฉพาะ สถานะปัจจุบัน ของแต่ละแห่ง ข้อมูลเดือนเก่าถูกย้ายไป คลังเอกสารเก่าเป็นไฟล์บีบอัดแยกกันเดือนต่อเดือน ไม่มีใครต่อให้เป็นอนุกรมเวลา คำถามอย่าง “สถานที่ไหนคะแนนกำลังตกต่อเนื่อง” หรือ “อุตสาหกรรมฟื้นจาก COVID แล้วหรือยัง” จึงตอบไม่ได้เลยถ้าไม่ประกอบคลังข้อมูลขึ้นมาเอง — นี่คือเหตุผลที่โครงการนี้มีอยู่

## 1.1 ปัญหาทางธุรกิจที่ต้องการแก้

เอกสารนี้สมมติบทบาทเป็นทีมวางแผนกลยุทธ์ของ ผู้ประกอบการเครือข่ายสถานดูแลผู้สูงอายุ หรือกองทุนที่กำลังพิจารณาลงทุนในธุรกิจนี้ ปัญหาที่เผชิญมีสี่ข้อ

1. ตัดสินใจขยายตลาดโดยไม่มีข้อมูลรองรับ — ไม่รู้ว่ารัฐใดมีอุปสงค์เหลืออยู่ (ผู้สูงอายุมากแต่เตียงน้อย) และคู่แข่งในพื้นที่นั้นอ่อนแอพอให้เข้าไปแข่งได้
2. ไม่รู้ว่าควรลงทุนด้านพนักงานเท่าไรจึงคุ้ม — การเพิ่มชั่วโมงพยาบาลคือต้นทุน ที่เห็นทันทีในงบเดือนนี้ แต่ผลตอบแทนมาช้าและวัดยาก
3. ความเสี่ยงด้านกฎระเบียบมองไม่เห็นล่วงหน้า — รู้ตัวอีกทีเมื่อถูกปรับไปแล้ว ทั้งที่สัญญาณเตือนปรากฏในข้อมูลมาก่อนหลายเดือน
4. ข้อมูลกระจายกระจายตามเวลา — ตามที่อธิบายในกล่องน้ำเงินด้านบน

## 2 ใครใช้ข้อมูลนี้ (Stakeholders)

| ผู้ใช้                          | ต้องตัดสินใจอะไร                            | ต้องการอะไรจากแดชบอร์ด                                            |
|---------------------------------|---------------------------------------------|-------------------------------------------------------------------|
| CEO / หัวหน้าฝ่ายขาย<br>กิจการ  | เลือกตลาดที่จะเข้าไปลงทุนหรือซื้อ<br>กิจการ | ภาพเปรียบเทียบรายรัฐ: อุปสงค์ เทียบ<br>อุปทาน เทียบ คุณภาพคู่แข่ง |
| COO / ผู้จัดการภูมิภาค          | จัดลำดับว่าจะเข้าไปแก้ที่ไหนก่อน            | รายชื่อสถานที่ที่คะแนนกำลังตก พร้อมระดับ<br>ความแรงด่วน           |
| ผู้อำนวยการฝ่ายบุคคล            | วางแผนอัตรากำลังและลดการลา<br>ออก           | ความสัมพันธ์ ชั่วโมงพยาบาล – อัตราลาออก –<br>คะแนนคุณภาพ          |
| CFO / นักลงทุนสัมพันธ์          | ประเมินผลตอบแทนและความเสี่ยง                | มูลค่าค่าปรับ อัตราการเข้าพัก และตัวคูณเงิน<br>จูงใจ VBP          |
| ฝ่ายกำกับปฏิบัติตาม<br>กฎ       | บริหารความเสี่ยงด้านกฎระเบียบ               | แนวโน้มค่าปรับ ประเภทข้อบกพร่องที่พบบ่อย<br>สถานะ Special Focus   |
| (ภายนอก) ครอบครัวผู้สูง<br>อายุ | เลือกสถานที่ให้ญาติผู้ใหญ่                  | เปรียบเทียบคุณภาพของสถานที่ในพื้นที่<br>เดียวกัน                  |

**ตารางที่ 1:** ผู้ใช้งานข้อมูลหกกลุ่ม คอลัมน์กลางคือสิ่งที่ทำให้แดชบอร์ดมีประโยชน์จริง — ถ้ากราฟใดไม่ช่วยตัดสินใจข้อใดข้อหนึ่งในคอลัมน์นี้ ก็ไม่ควรอยู่บนหน้าจอ

## 3 คำถามทางธุรกิจแปดข้อ

โจทย์กำหนดอย่างน้อย 5 ข้อ ตั้งไว้ 8 ข้อเพื่อให้มีระยะเผื่อ คอลัมน์ขวาสุดคือเครื่องมือตรวจสอบตัวเอง: ถ้าคำถามข้อใดไม่มีตารางรองรับ แปลว่าผังที่ออกแบบไว้ยังไม่พอ

| #   | คำถาม                                                                                                            | ผู้ใช้         | ตอบด้วยตารางใด                                        |
|-----|------------------------------------------------------------------------------------------------------------------|----------------|-------------------------------------------------------|
| BQ1 | รัฐใดนำเข้าไปลงทุนที่สุด เมื่อดูจำนวนเตียงต่อประชากรสูง อายุพันคน อัตราการเข้าพักเฉลี่ย และคะแนนคุณภาพของคู่แข่ง | CEO            | Fact_Facility_Monthly × Dim_Geography + ข้อมูลประชากร |
| BQ2 | รูปแบบการถือครองแบบใดให้ผลต่างกันอย่างไร ทั้งด้านคุณภาพ ชั่วโมงพยาบาล และค่าปรับต่อเตียง                         | CEO, CFO       | ทั้งสอง Fact × Dim_Ownership                          |
| BQ3 | ชั่วโมงพยาบาลต่อผู้พักอาศัยต่อวันสัมพันธ์กับคะแนนดาวและค่าปรับอย่างไร และจุดคุ้มอยู่ที่ระดับใด                   | ฝ่ายบุคคล, CFO | Fact_Facility_Monthly                                 |
| BQ4 | อัตราการลาออกของพยาบาลสูงแค่ไหนจึงเริ่มลดคุณภาพและอัตราการเข้าพัก                                                | ฝ่ายบุคคล      | Fact_Facility_Monthly                                 |
| BQ5 | แนวโน้มปี 2562–2569 ของอัตราการเข้าพัก ชั่วโมงพยาบาล และคะแนนดาว เป็นอย่างไร พิจารณาจาก COVID แล้วหรือยัง        | CEO, CFO       | Fact_Facility_Monthly × Dim_Date                      |
| BQ6 | สถานที่ใดกำลังเสื่อมคุณภาพและมีแนวโน้มถูกลงโทษ                                                                   | COO, กำกับกฎ   | ทั้งสอง Fact × Dim_Facility (SCD2)                    |
| BQ7 | ค่าปรับกระจุกตัวที่รัฐใดและช่วงเวลาใด รัฐใดบังคับใช้กฎหมายที่รุนแรงที่สุดต่อเตียง                                | กำกับกฎ        | Fact_Penalty_Event × Dim_Geography, Dim_Date          |
| BQ8 | เครือข่ายขนาดใหญ่ได้เปรียบจริงหรือไม่ — คุณภาพดีกว่า หรือแค่กดดันทุนแรงงาน                                       | CEO            | Fact_Facility_Monthly × Dim_Chain                     |

**ตารางที่ 2:** คำถามทางธุรกิจแปดข้อ ทุกข้อมีตารางรองรับครบ ซึ่งเป็นหลักฐานว่าผัง Star Schema ในภาค 4 ออกแบบมาพอดีกับสิ่งที่ต้องตอบ ไม่ได้ออกแบบลอย ๆ

#### BQ1 เป็นข้อเดียวที่พึ่งข้อมูลนอก CMS

ถ้าดึงข้อมูลประชากรอายุ 65 ปีขึ้นไปไม่สำเร็จ จะลดรูปเหลือ “เตียงต่อประชากรทั้งรัฐ” หรือตัด BQ1 ทิ้งแล้วยังเหลือ 7 ข้อ ซึ่งยังเกินเกณฑ์ วางแผนทางถอยไว้ตั้งแต่ตอนนี เพราะถ้าไปเจอตอนเขียนแดชบอร์ดจะแก้ไม่ทัน

## 4 Measures และกับดักของการรวมค่า

โจทย์กำหนดอย่างน้อย 3 ตัว และให้อธิบาย *ความหมาย วิธีคำนวณ และประโยชน์* เอกสารนี้เพิ่มคอลัมน์ **การรวมค่า (additivity)** เข้าไปด้วย เพราะเป็นสิ่งที่ตัดสินใจว่า แดชบอร์ดจะสรุปตัวเลขถูกหรือผิด

| Measure                      | วิธีคำนวณ                                        | การรวมค่า                   | ความหมายและประโยชน์                                                         |
|------------------------------|--------------------------------------------------|-----------------------------|-----------------------------------------------------------------------------|
| M1 อัตราการเข้าพัก           | SUM(avg_residents_per_day) / SUM(certified_beds) | รวมตรง ๆ ไม่ได้ (อัตราส่วน) | ตัวชี้วัดรายได้หลัก ต่ำกว่า 80% มักหมายถึงขาดทุน                            |
| M2 วัน-ผู้พักอาศัย           | avg_residents_per_day × จำนวนวันในงวด            | รวมได้                      | ปริมาณบริการที่ขายได้จริง ใช้ถ่วงน้ำหนัก measure อื่น                       |
| M3 ชั่วโมงพยาบาลต่อคนต่อวัน  | reported_total_nurse_hprd (ถ่วงน้ำหนักด้วย M2)   | รวมตรง ๆ ไม่ได้             | ตัวแทนของต้นทุนแรงงาน และเป็นตัวพยากรณ์คุณภาพที่แรงที่สุด                   |
| M4 อัตราการลาออก             | total_nursing_turnover_pct (ถ่วงน้ำหนักด้วย M2)  | รวมตรง ๆ ไม่ได้             | ต้นทุนแฝงจากการสรรหาและฝึกอบรม และเป็นสัญญาณเตือนคุณภาพ                     |
| M5 มูลค่าค่าปรับ             | SUM(fine_amount_usd) จาก Fact_Penalty_Event      | รวมได้                      | ต้นทุนความเสี่ยงด้านกฎระเบียบที่จับต้องได้เป็นเงิน                          |
| M6 จำนวนครั้งที่ถูกลงโทษ     | COUNT(*) จาก Fact_Penalty_Event                  | รวมได้                      | ใช้คู่กับ M5 เพื่อแยก “ถูกปรับบ่อยที่ละน้อย” ออกจาก “ถูกปรับหนักครั้งเดียว” |
| M7 คะแนนดาวเฉลี่ย            | AVG(overall_rating) ช่วง 1–5                     | รวมตรง ๆ ไม่ได้             | ตัวแปรที่ครอบคลุมผู้สูงอายุใช้ตัดสินใจมากที่สุด                             |
| M8 จำนวนข้อบกพร่อง           | SUM(cycle1_total_deficiencies)                   | รวมได้                      | ตัวชี้วัดปฏิบัติการที่ “มาก่อน” การถูกปรับ                                  |
| M9 ค่าปรับต่อวัน-ผู้พักอาศัย | M5 / M2                                          | คำนวณตอน query              | ทำให้เทียบความเสี่ยงระหว่างสถานที่ต่างขนาดได้อย่างเป็นธรรม                  |
| M10 เติบโตของผู้สูงอายุ      | SUM(certified_beds) / (ประชากร 65+ / 1000)       | คำนวณตอน query              | ความอึดตัวของตลาด ค่าต่ำแปลว่ายังมีอุปสงค์เหลือ (ใช้ตอบ BQ1)                |

**ตารางที่ 3:** Measures สืบตัว M1–M8 เก็บในตาราง Fact ส่วน M9–M10 ไม่เก็บแต่คำนวณตอนสอบถาม เพราะเป็นอัตราส่วนที่หาได้จากตัวอื่น การเก็บซ้ำมีแต่จะทำให้ข้อมูลซ้ำกันเอง

### ความผิดพลาดที่พบบ่อยที่สุดในงานคลังข้อมูล: เฉลี่ยของอัตราส่วน

สมมติมีสองแห่ง แห่งแรก 10 เตียง มีผู้พัก 5 คน (50%) แห่งที่สอง 200 เตียง มีผู้พัก 180 คน (90%)

AVG(occupancy) ให้  $(50 + 90)/2 = 70\%$

วิธีที่ถูกต้องคือ SUM(residents)/SUM(beds) ให้  $185/210 = 88.1\%$

ต่างกัน 18 จุด และค่าที่ผิดจะ *ต่ำกว่าความจริงเสมอ* เมื่อสถานที่ใหญ่ทำได้ดีกว่า แดชบอร์ดที่ลากอัตราส่วนไปวางแล้วให้เครื่องมือเฉลี่ยให้เอง จะผิดแบบนี้ทุกครั้ง จึงต้องเก็บ **ตัวตั้งและตัวหารแยกกัน** ในตาราง Fact แล้วหารตอนแสดงผล


## ภาคที่ 2

## แหล่งข้อมูล — มาจากไหน มีอะไร ใช้ทำอะไร

ภาคนี้ตอบคำถามว่า: ข้อมูลทุกตัวเลขที่จะขึ้นบนแดชบอร์ด สืบกลับไปถึงไฟล์ไหนบนเซิร์ฟเวอร์ใคร

โจทย์กำหนดให้ใช้ อย่างน้อย 3 แหล่ง และอย่างน้อยหนึ่งแหล่งต้องซับซ้อนกว่า CSV ตารางทั่วไป โครงการนี้ใช้ 3 แหล่งหลัก และ 2 แหล่งเสริม

### 5 ภาพรวมทั้งห้าแหล่ง



รูปที่ 3: ทางเดินของข้อมูลทั้งระบบ ห้าแหล่งไหลผ่าน ETL ชัดเดียวลงสู่สองตาราง Fact และหกตาราง Dimension แล้วจึงขึ้นแดชบอร์ด สีในผังนี้คือสีเดียวกับที่ใช้เรียกกระยะต่าง ๆ ตลอดเอกสาร

## 6 แหล่งที่ 1 — CMS Nursing Homes Archived Snapshots

### 6.1 มาจากไหน

- ผู้เผยแพร่: Centers for Medicare & Medicaid Services (CMS) กระทรวงสาธารณสุขสหรัฐอเมริกา ผ่านระบบ Provider Data Catalog
- หน้าเว็บ: <https://data.cms.gov/provider-data/archived-data/nursing-homes>
- ลิงก์ไฟล์จริง: หน้าเว็บนั้นเป็นแอปแบบ JavaScript จึงไม่มีลิงก์ในโค้ด HTML ต้องดึงรายการผ่าน API (แหล่ง S2) ซึ่งคืนที่อยู่ไฟล์ในรูปแบบ  
/provider-data/sites/default/files/dataset-archives/theme/  
nursing-homes/nursing-homes\_2026-06-24.zip
- สิทธิการใช้งาน: ข้อมูลสาธารณะของรัฐบาลสหรัฐฯ ใช้ได้เสรี ต้องอ้างอิงแหล่งที่มา

### สิ่งที่ตรวจสอบแล้วเกี่ยวกับแหล่งนี้

มี 88 snapshot รายเดือน ตั้งแต่ 17 ม.ค. 2562 ถึง 6 ส.ค. 2569 และมีชุดรวมรายปีอีก 8 ชุด ไฟล์รายเดือนมีขนาดราว 32–40 MB เมื่อบีบอัด ยกเว้นบางเดือนที่ผิดปกติ เช่น 29 ก.ค. 2569 มีขนาด 622 MB และ 6 ส.ค. 2569 มีเพียง 3.5 MB (น่าจะเป็นการอัปเดตบางส่วน) — ขั้นตอน ETL จึงต้องไม่สมมติว่าทุก snapshot มีไฟล์ครบเท่ากัน

## 6.2 มีอะไรอยู่ข้างใน

เปิดไฟล์ nursing-homes\_2026-06-24.zip (38 MB บีบอัด) พบ 20 ไฟล์ รวม 614 MB เมื่อคลาย รายการด้านล่างคือของจริงทั้งหมด

| ไฟล์                                 | แถว    | คอลัมน์ | เนื้อหา                                                        |
|--------------------------------------|--------|---------|----------------------------------------------------------------|
| NH_ProviderInfo                      | 14,695 | 99      | โปรไฟล์ คะแนนดาว ชั่วโมงพยาบาล อัตราลาออก เต็ม ที่ตั้ง เจ้าของ |
| NH_Penalties                         | 16,180 | 14      | ค่าปรับและการระงับการจ่ายเงินรายรายการ พร้อมวันที่และจำนวนเงิน |
| NH_SurveySummary                     | 43,952 | 41      | สรุปผลการตรวจแยกตามหมวดข้อบกพร่อง 30 หมวด                      |
| FY_2026_SNF_VBP_Facility_Performance | 13,900 | 49      | คะแนนและตัวคูณเงินจูงใจ (ดูแหล่ง S3)                           |
| NH_CitationDescriptions              | 643    | 5       | คำอธิบายรหัสข้อบกพร่องแต่ละรหัส                                |
| NH_StateUSAverages                   | 54     | 51      | ค่าเฉลี่ยรายรัฐและระดับประเทศ                                  |
| NH_HealthCitations                   | 165 MB |         | ข้อบกพร่องรายรายการ ไฟล์ใหญ่ที่สุด                             |
| NH_Ownership                         | 56 MB  |         | นิติบุคคลผู้ถือครองแต่ละราย หนึ่งแห่งมีได้หลายราย              |
| NH_QualityMsr_MDS                    | 75 MB  |         | ตัวชี้วัดคุณภาพจากแบบประเมินผู้พักอาศัย                        |
| NH_QualityMsr_Claims                 | 17 MB  |         | ตัวชี้วัดคุณภาพจากข้อมูลการเบิกจ่าย                            |
| NH_FireSafetyCitations               | 69 MB  |         | ข้อบกพร่องด้านความปลอดภัยจากอัคคีภัย                           |
| NH_SurveyDates                       | 7.8 MB |         | วันที่เข้าตรวจแต่ละรอบ                                         |

อีก 8 ไฟล์ที่เหลือเป็นข้อมูลประกอบขนาดเล็กและคู่มือ NH\_Data\_Dictionary.pdf

**ตารางที่ 4:** ไฟล์ทั้งหมดใน snapshot เดือนมิถุนายน 2569 ตัวเลขแถวและคอลัมน์มาจากการเปิดไฟล์จริง โครงงานนี้จะใช้เพียง 6 ไฟล์แรก ส่วนที่เหลือระบุไว้เพื่อให้เห็นว่าตัดอะไรออกและตัดเพราะอะไร

## 6.3 ใช้ทำอะไร

| ไฟล์                    | ป้อนตารางใด                                       | ตอบคำถามข้อใด |
|-------------------------|---------------------------------------------------|---------------|
| NH_ProviderInfo         | Fact_Facility_Monthly และ Dimension ทั้ง 5 ตัวแรก | BQ1–BQ6, BQ8  |
| NH_Penalties            | Fact_Penalty_Event, Dim_Penalty_Type              | BQ2, BQ6, BQ7 |
| NH_SurveySummary        | สำรองไว้สำหรับ Fact ที่ 3 (ถ้ามีเวลา)             | ขยาย BQ7      |
| NH_CitationDescriptions | ตาราง lookup แพลทฟอร์มเป็นคำอธิบาย                | BQ7           |
| NH_StateUSAverages      | ค่าอ้างอิงเปรียบเทียบบนกราฟ                       | BQ1, BQ5      |

**ตารางที่ 5:** การจับคู่ไฟล์กับตารางปลายทาง ไฟล์ที่ไม่ปรากฏในตารางนี้จะไม่ถูกคลายออกจาก ZIP เลย เพื่อไม่ให้เสียเวลาและพื้นที่ไปกับข้อมูล 165 MB ที่ไม่ได้ใช้

### ทำไมแหล่งนี้จึงนับว่า “ซับซ้อนกว่า CSV ตารางทั่วไป”

โจทย์ยากตัวอย่างความซับซ้อนไว้ข้อหนึ่งว่า “ข้อมูลจากหลายไฟล์หรือหลายช่วงเวลา” ซึ่งแหล่งนี้ตรงเป๊ะ: ต้องวนดาวน์โหลดหลายสิบไฟล์ คลายบีบอัด จับคู่ชื่อไฟล์ที่เปลี่ยนไปเรื่อย แล้วต่อกันเป็นอนุกรมเวลาเอง ไม่มีไฟล์ใดไฟล์หนึ่งที่เปิดแล้วได้ข้อมูลย้อนหลังทันที

### ชื่อไฟล์มีอย่างน้อย 3 แบบ ไม่ใช่แค่เปลี่ยนเดือน [ตรวจแล้ว]

เปิด snapshot ปี 2562 เทียบกับปี 2569 จังแล้วพบว่าไม่ได้ต่างกันแค่เดือน แต่มันต่างกันทั้ง ระบบตั้งชื่อ

| ยุค            | รูปแบบชื่อไฟล์                                                                   |
|----------------|----------------------------------------------------------------------------------|
| 2562           | ProviderInfo_Download.csv, Penalties_Download.csv — ไม่มี NH_ ไม่มี เดือน        |
| 2569 (ปกติ)    | NH_ProviderInfo_Jun2026.csv — มี prefix และเดือน                                 |
| 2569 (บางส่วน) | 4pq5-n9py_2026-07-29_NH_ProviderInfo_Jul2026.csv — มีรหัสชุดข้อมูล นำหน้าอีกชั้น |

การ จับ คู่ ด้วย glob ธรรมดา จัง พัง แน่นอน ต้อง ใช้ การ จับ คู่ แบบ regex ต่อ ยุค หรือ อ่าน จาก manifest.json ถ้ามี

### snapshot “บางส่วน” มีอยู่จริง และ ETL ต้องรับมือ [ตรวจแล้ว]

งวด 2026-08-06 ที่มีขนาดผิดปกติ 3.5 MB เปิดดูแล้ว มีเพียง 4 ไฟล์: NH\_ProviderInfo, NH\_StateUSAverages, manifest.json และคู่มือ — ไม่มี NH\_Penalties เลย

ถ้า ETL สมมติว่าทุก snapshot มีครบ 6 ไฟล์ที่ต้องใช้ งวดนี้จะทำให้ท้อพัง หรือแย่กว่านั้นคือโหลด Fact 2 ได้ศูนย์แถวแบบเงียบ ๆ

**กฎที่ต้องเขียน:** ตรวจสอบรายชื่อไฟล์ก่อนประมวลผลทุกงวด งวดใดขาดไฟล์ให้ข้ามเฉพาะ Fact ที่เกี่ยวข้อง ไม่ใช่ข้ามทั้งงวด และบันทึกลงตารางบันทึกการทำงาน

### ขอบเขตที่ตัดสินใจไว้แล้ว: โหลดรายไตรมาส ไม่ใช่ทุกเดือน

88 snapshot × 38 MB คือการดาวน์โหลดรวม 3.3 GB และคะแนนดาวเปลี่ยนช้าเกินกว่าจะ ให้ข้อมูลเพิ่มรายเดือน จึงเลือกไตรมาสละหนึ่ง snapshot ได้ประมาณ 28–31 จุดเวลา ครอบคลุมช่วงเดียวกัน แต่ดาวน์โหลดลดลงเหลือราวหนึ่งในสาม ถ้าภายหลังพบว่าความละเอียดไม่พอ เพิ่ม snapshot ได้โดยไม่ต้องรื้อผัง เพราะ Grain กำหนดไว้ที่ “ต่อ snapshot” ไม่ใช่ “ต่อเดือน”

## 7 แหล่งที่ 2 — CMS Provider Data Catalog REST API

### 7.1 มาจากไหน

เป็น API สาธารณะของ CMS ที่อยู่ใต้โดเมนเดียวกัน ใช้สามปลายทาง

| # | ปลายทาง (ต่อท้าย <a href="https://data.cms.gov/provider-data/api/1/">https://data.cms.gov/provider-data/api/1/</a> ) | คืออะไร                                                                  |
|---|----------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------|
| A | archive/aggregate/theme/nursing-homes/relative                                                                       | รายการ snapshot ทั้งหมด 96 รายการ พร้อม URL ขนาด และวันที่               |
| B | metastore/schemas/dataset/items                                                                                      | แคตตาล็อกชุดข้อมูลทั้งหมด 234 ชุด ในจำนวนนี้เป็นของ Nursing Homes 11 ชุด |
| C | datastore/query/4pq5-n9py/0?limit=1                                                                                  | ข้อมูลแถวจริงของชุด Provider Information เป็น JSON ชื่อเคสแบบ snake_case |

**ตารางที่ 6:** สามปลายทางของ API ที่โครงการนี้ใช้ รหัสอย่าง 4pq5-n9py คือรหัสชุดข้อมูลที่ได้มาจากปลายทาง B จึงไม่ต้องจดจำเอง

### 7.2 มีอะไร

ปลายทาง A คืนข้อมูลหน้าตาแบบนี้ (ตัดมาหนึ่งรายการ)

```
{
  "name": "Theme: nursing-homes (2026-06-24)",
  "id": "8681",
  "type": "theme",
  "theme": "nursing-homes",
  "url": "/provider-data/sites/default/files/dataset-archives/theme/nursing-homes/nursing-homes_2026-06-24.zip",
  "size": "38990000",
  "date": "2026-06-24",
  "access_level": "public"
}
```

ส่วนปลายทาง C คือนำข้อมูลจริง ตัวอย่างแรกคือ

```
{
  "cms_certification_number_ccn": "015009",
  "provider_name": "BURNS NURSING HOME, INC.",
  "citytown": "RUSSELLVILLE", "state": "AL", "zip_code": "35653",
  "ownership_type": "For profit - Corporation",
  "number_of_certified_beds": "57",
  "average_number_of_residents_per_day": "51.6", ...
}
```

### แถวตัวอย่างนี้เรียกมาจริงแล้ว และใช้เป็นกรณีทดสอบได้

สถานที่ CCN 015009 มี 57 เตียง มีผู้พักอาศัยเฉลี่ย 51.6 คนต่อวัน  $\Rightarrow$  อัตราการเข้าพัก  $51.6/57 = 90.5\%$

### กับดัก: แถวทดสอบนี้ผูกกับ “งวด” ห้ามใช้ลอย ๆ

**[ตรวจสอบแล้ว]** ตรวจสอบแล้วพบว่า ค่าเดียวกันนี้ไม่ตรงกันระหว่างสองแหล่ง เพราะเป็นคนละงวด

| แหล่ง                          | Processing Date | ผู้พักอาศัย | อัตราเข้าพัก |
|--------------------------------|-----------------|-------------|--------------|
| API ปลายทาง C (ข้อมูลปัจจุบัน) | 2026-07-01      | 51.6        | 90.53%       |
| CSV NH_ProviderInfo_Jun2026    | 2026-06-01      | 52.4        | 91.93%       |

ETL โหลดจาก CSV ไม่ใช่จาก API ดังนั้นการทดสอบต้องคาดหวัง **91.93%** สำหรับงวด มิ.ย. 2569 ถ้าเขียนเทสให้เช็ค 90.5% ลอย ๆ เทสจะแดงทั้งที่ถูกต้อง

บทเรียนที่ใหญ่กว่านั้น: ค่าทดสอบทุกตัวต้องระบุงวดกำกับเสมอ และนี่คือหลักฐานตรง ๆ ว่าปลายทาง C ใช้ “ตรวจสอบความถูกต้องหลัง Load” ได้เฉพาะกับงวดล่าสุดเท่านั้น

## 7.3 ใช้ทำอะไร

- ค้นหา snapshot อัตโนมัติ (ปลายทาง A) — ทำให้ ETL รู้เองว่ามีข้อมูลเดือนใหม่ โดยไม่ต้องมีคนไปคัดลอกสิ่งมาแปะ นี่คือการทำให้ รันซ้ำได้ ตามที่โจทย์บังคับ
- ทำ Incremental Load — เทียบรายการจาก A กับไฟล์ที่มีอยู่แล้วในเครื่อง แล้วโหลดเฉพาะส่วนต่าง
- ตรวจสอบความถูกต้องหลัง Load — ดึงข้อมูลปัจจุบันจากปลายทาง C มาเทียบกับแถวล่าสุดในคลังข้อมูล ถ้าไม่ตรงแปลว่า ETL แปลงค่าผิดที่ไหนสักแห่ง

### API คือสิ่งที่แยก “ไปป์ไลน์” ออกจาก “การดาวน์โหลดด้วยมือ”

โจทยระบุชัดว่า “กระบวนการควรสามารถรันซ้ำได้ โดยไม่ต้องแก้ไขข้อมูลด้วยมือทุกขั้นตอน” และให้คะแนนพิเศษกับ การใช้ API กับ การทำ Incremental Load ปลายทาง A ตัวเดียวตอบทั้งสามข้อนี้พร้อมกัน ด้วยโค้ดไม่กี่บรรทัด

## 8 แหล่งที่ 3 — SNF VBP Facility Performance

### 8.1 มาจากไหน มีอะไร

ไฟล์ FY\_2026\_SNF\_VBP\_Facility\_Performance.csv อยู่ใน ZIP เดียวกับแหล่ง S1 แต่นับเป็นคนละแหล่ง เพราะเป็นคนละโครงการของ CMS คนละรอบเวลา และ **คนละ Grain** — เป็นข้อมูลราย *ปีงบประมาณ* ขณะที่ทุกอย่างใน S1 เป็นรายเดือน

ขนาด 13,900 แถว × 49 คอลัมน์ **[ตรวจแล้ว]** เนื้อหาคือคะแนนของโครงการ Skilled Nursing Facility Value-Based Purchasing ซึ่งวัดสี่ด้าน

| ตัวชี้วัด                              | ความหมายทางธุรกิจ                                         |
|----------------------------------------|-----------------------------------------------------------|
| อัตราการกลับเข้าโรงพยาบาล              | ผู้ป่วยที่ต้องกลับเข้าโรงพยาบาลหลังจากสถานดูแล            |
| อัตราการติดเชื้อในสถานพยาบาล           | ตัวชี้วัดคุณภาพการควบคุมการติดเชื้อ                       |
| อัตราการลาออกของพยาบาล                 | เชื่อมกับ M4 โดยตรง ยืนยันว่า CMS เองก็ถือว่านี่คือคุณภาพ |
| ชั่วโมงพยาบาลปรับตามความหนักของผู้ป่วย | เชื่อมกับ M3                                              |
| ตัวคูณเงินจูงใจ                        | ผลลัพธ์สุดท้าย: ตัวคูณที่ใช้กับเงินที่ CMS จ่ายให้จริง    |

**ตารางที่ 7:** สี่ตัวชี้วัดของโครงการ VBP และผลลัพธ์ที่เป็นตัวเงิน คอลัมน์สุดท้ายคือสิ่งที่ทำให้แหล่งนี้มีค่าต่อ CFO เพราะเป็นจุดเดียวในข้อมูลทั้งหมดที่แปลงคุณภาพเป็นรายได้ได้โดยตรง

### 8.2 ใช้ทำอะไร

เชื่อมเข้ากับ Fact\_Facility\_Monthly ด้วย CCN แล้วเพิ่มมิติ “ผลตอบแทน” ให้กับคำถาม BQ2 และ BQ3 — เปลี่ยนคำถามจาก “ลงทุนพนักงานแล้วคะแนนดีขึ้นไหม” เป็น “ลงทุนพนักงานแล้ว *ได้เงินคืน* เท่าไร” ซึ่งเป็นคำถามที่ CFO สนใจจริง

#### การเชื่อมข้าม Grain ต้องระวังการนับซ้ำ

VBP มีหนึ่งแถวต่อสถานที่ต่อ *ปีงบประมาณ* แต่ Fact 1 มีหลายแถวต่อสถานที่ต่อปี ถ้า JOIN ตรง ๆ ค่าตัวคูณเงินจูงใจจะถูกทำซ้ำในทุกงวด และการ SUM จะได้ค่าเกินจริงหลายเท่า

วิธีจัดการ: เก็บตัวคูณไว้เป็น **แอตทริบิวต์ระดับปี** แล้วใช้เฉพาะกับการรวมค่า ที่ระดับปีเท่านั้น ห้ามให้มันไหลลงไปที่ระดับงวด

## 9 แหล่งเสริมอีกสองแหล่ง

### 9.1 S4 — ประชากรอายุ 65 ปีขึ้นไป รายรัฐ

มาจาก U.S. Census Bureau American Community Survey ผ่าน API ที่คืน nested JSON ใช้เป็น **ฝั่งอุปสงค์** ของตลาด ซึ่งข้อมูล CMS ทั้งหมดไม่มีให้ เพราะ CMS มองแต่ฝั่งผู้ให้บริการ

การคำนวณไม่ตรงไปตรงมา: ตาราง B01001 แยกประชากรตามเพศและช่วงอายุย่อย จึงต้องรวมตัวแปรหลายตัว (ชาย 65–66, 67–69, 70–74, ... และหญิงชุดเดียวกัน) เข้าด้วยกันเองจึงจะได้ “ประชากร 65+”

### หาค่าที่เรียกไม่สำเร็จได้แล้ว — Census บังคับใช้ API key

**[ตรวจสอบแล้ว]** อาการ “คั่นกว้าง” ไม่ใช่พารามิเตอร์ผิดหรือปีไม่มีข้อมูล แต่เป็นเพราะ Census ตอบกลับด้วย HTTP 302 ซึ่งไปที่ [https://api.census.gov/data/missing\\_key.html](https://api.census.gov/data/missing_key.html) ซึ่งเป็นหน้า HTML ถ้า curl ไม่ได้ใส่ -L จะได้ body ว่างเปล่าโดยไม่มี error — ตรงกับอาการที่บันทึกไว้ทุกประการ

**วิธีแก้:** ขอคีย์ฟรีที่ [api.census.gov/data/key\\_signup.html](https://api.census.gov/data/key_signup.html) แล้วต่อ &key=... ท้าย URL เก็บคีย์ไว้ในตัวแปรสภาพแวดล้อม ห้าม hard-code ลงในโค้ดที่ commit

### ตัวแปร 12 ตัวที่ต้องบวกกันเพื่อให้ได้ “ประชากร 65+”

ยืนยันชื่อตัวแปรจาก groups/B01001.json แล้ว **[ตรวจสอบแล้ว]** (metadata ไม่ต้องใช้คีย์)

ชาย: B01001\_020E (65–66), 021E (67–69), 022E (70–74), 023E (75–79), 024E (80–84), 025E (85+)

หญิง: B01001\_044E ถึง 049E ตามช่วงอายุเดียวกัน

### ทางลัดที่ทดสอบแล้วว่าใช้ได้ และไม่ต้องใช้คีย์เลย

**[ตรวจสอบแล้ว]** ถ้าขอคีย์ไม่ทัน ใช้แฟ้ม Population Estimates แบบ CSV นิ่งแทนได้ ไม่มีระบบคีย์มาเกี่ยวข้อง

[www2.census.gov/programs-surveys/popest/datasets/](https://www2.census.gov/programs-surveys/popest/datasets/)

2020-2024/state/asrh/sc-est2024-agesex-civ.csv (812 KB, HTTP 200)

กรอง SEX=0 และ AGE>=65 (ตัด AGE=999 ซึ่งเป็นแถวผลรวมออก) แล้วรวมตาม NAME ได้ครบ 50 รัฐ + DC + ผลรวมประเทศ ทดสอบแล้วได้ยอดทั้งประเทศ **61.2 ล้านคน** ซึ่งสมเหตุสมผล

## 9.2 S5 — ตาราง lookup ของ CMS

NH\_CitationDescriptions (643 แถว) แปลรหัสข้อบกพร่องเป็นคำอธิบายและหมวดหมู่ ส่วน NH\_StateUSAverages (54 แถว × 51 คอลัมน์) ให้ค่าเฉลี่ยรายรัฐและระดับประเทศใช้เป็นเส้นอ้างอิงบนกราฟ เพื่อให้ผู้อ่านรู้ค่าที่เห็นดีหรือแย่กว่ามาตรฐาน

## 10 ตารางสืบย้อน — แหล่งไหนตอบคำถามไหน

ตารางนี้คือคำตอบรวบยอดของคำถาม “ข้อมูลมาจากไหน มีอะไร ใช้ทำอะไร” และเป็นสิ่งที่ควรคัดลอกไปใส่รายงานฉบับส่งโดยตรง

| #  | แหล่ง                           | รูปแบบ                       | ให้ข้อมูลอะไร                                             | ป้อนตารางใด                                    | ตอบข้อใด             |
|----|---------------------------------|------------------------------|-----------------------------------------------------------|------------------------------------------------|----------------------|
| S1 | CMS Archived Snapshots          | ZIP หลายไฟล์<br>หลายช่วงเวลา | โปรไฟล์ คะแนน ชั่วโมง<br>พยาบาล ค่าปรับ ย้อน<br>หลัง 7 ปี | Fact 1, Fact 2, Dim<br>ทั้งหมด                 | BQ1–BQ8              |
| S2 | CMS Provider Data API           | JSON ผ่าน<br>HTTP            | รายการ snapshot และ<br>แถวข้อมูลปัจจุบัน                  | ไม่ป้อนตารางโดยตรง แต่ใช้<br>ETL และใช้ตรวจสอบ | ทุกข้อ (ทาง<br>อ้อม) |
| S3 | SNF VBP Facility<br>Performance | CSV ราย<br>ปีงบประมาณ        | ตัวคูณเงินจูงใจและ<br>คะแนนผู้दान                         | แอตทริบิวต์ระดับปีของ Fact<br>1                | BQ2, BQ3             |
| S4 | Census ACS API                  | Nested JSON                  | ประชากรอายุ 65+ รายรัฐ                                    | Dim_Geography                                  | BQ1                  |
| S5 | CMS lookup tables               | CSV เล็ก                     | คำอธิบายรหัส และค่า<br>เฉลี่ยอ้างอิง                      | ตาราง lookup และเส้น<br>อ้างอิงบนกราฟ          | BQ1, BQ5,<br>BQ7     |

**ตารางที่ 8:** ตารางสืบย้อนแหล่งข้อมูล อ่านจากซ้ายไปขวาจะได้ประโยคเต็มว่า แหล่งนี้มาจากไหน หน้าตาอย่างไร ให้อะไร ไปอยู่ตรงไหน และตอบคำถามข้อใด ทุกคำถามธุรกิจมีแหล่งรองรับครบ

ภาคที่ 3

## คุณภาพข้อมูล — อะไรพังบ้าง

ภาคนี้ตอบคำถามว่า: ข้อมูลเปิดของรัฐบาลสะอาดพอจะใช้เลยไหม (คำตอบคือไม่)

โจทย์กำหนดให้มีปัญหาคุณภาพข้อมูลอย่างน้อย 3 ประเภท เอกสารนี้ระบุไว้ 8 ประเภท ทุกข้อมีทั้งวิธีตรวจจับ และวิธีแก้ไขย่นไว้วางหน้า เพื่อให้ชั้น Clean ทำงานอัตโนมัติได้จริง

## 11 ปัญหาแปดประเภทและวิธีรับมือ

| #  | ประเภท                  | ปัญหาที่คาดว่าจะเจอ                                                                                                                                                                                                            | วิธีตรวจจับและแก้                                                                                                                                                                                         |
|----|-------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Q1 | คีย์ไม่ตรงกัน           | CCN เป็นรหัส 6 หลักที่มีศูนย์นำหน้า เช่น 015009 [ตรวจแล้ว] ถ้าอ่านเป็นตัวเลขจะเหลือ 15009 แล้วเชื่อมตารางไม่ติด                                                                                                                | บังคับอ่านเป็นข้อความทุกไฟล์ แล้วเติมศูนย์ให้ครบ 6 หลัก ตรวจด้วยเงื่อนไขว่าอัตราการเชื่อมสำเร็จต้องเกิน 99% ก่อนโหลดเข้าคลัง                                                                              |
| Q2 | ระเบียบซ้ำ              | สถานที่เดียวกันปรากฏใน ทุก snapshot และค่าปรับรายการเดิม ถูกรายงานซ้ำข้ามหลาย snapshot (แฟ้ม Penalties เป็นหน้าตาเหมือน 3 ปี [ตรวจแล้ว] ค่าปรับหนึ่งรายการจึงปรากฏซ้ำได้ถึง 36 งวด)                                            | Fact 1 ตั้งใจให้ซ้ำ (เป็นสถานะรายงวด) จึงใส่ snapshot ไว้ในคีย์หลัก ส่วน Fact 2 ต้องกำจัดซ้ำจริง ด้วยคีย์ สองระบบแยกตามยุค เพราะ Fine ID มีเฉพาะงวด 202606 เป็นต้นไป [ตรวจแล้ว] (ดูกล่องแดงท้ายหัวข้อนี้) |
| Q3 | ค่าว่าง                 | คะแนนดาวว่างสำหรับสถานที่เปิดใหม่ และ CMS ใช้คอลัมน์ footnote คู่กัน เพื่อบอกเหตุผลที่ค่าถูกระงับ (มีอย่างน้อย 9 คอลัมน์) [ตรวจแล้ว]                                                                                           | ไม่เติมค่าเดา แต่เก็บรหัส footnote ไว้ แล้วกันแถวที่ถูกระงับออกจากตัวหาร ตอนคำนวณค่าเฉลี่ย                                                                                                                |
| Q4 | ค่าที่เป็นไปไม่ได้      | ผู้พักอาศัยเฉลี่ยมากกว่าจำนวนเตียง ทำให้อัตราการเข้าพักเกิน 100% — เกิดขึ้นจริง 128 แห่ง (0.88%) และค่าสูงสุดคือ 1414% ซึ่งเป็นข้อผิดพลาดแน่นอน [ตรวจแล้ว]                                                                     | เขียนกฎตรวจเป็นฟังก์ชัน: อัตราการเข้าพักต้องอยู่ใน [0, 1.2] อัตราลาออกต้องอยู่ใน (0, 200] แถวที่ตกกฎ ติดธง ไม่ลบทิ้ง                                                                                      |
| Q5 | ชื่อหมวดไม่สอดคล้อง     | ประเภทการถือครองมีหลายค่า เช่น For profit - Corporation [ตรวจแล้ว] คาดว่าสะกดต่างกันข้ามปี และชื่อเครื่องมือมีปัญหาตัวพิมพ์และช่องว่างเกิน                                                                                     | ทำตารางจับคู่แบบระบุชุด ไม่ใช้การเดาความคล้าย จากค่าดิบไปเป็นกลุ่มการถือครอง 3 กลุ่ม ส่วนชื่อเครื่องมือให้ตัดช่องว่างและปรับตัวพิมพ์                                                                      |
| Q6 | รูปแบบวันที่ต่างกัน     | ตรวจปลายทางทั้งสองฝั่งแล้ว: ทั้ง ม.ค. 2562 และ มิ.ย. 2569 ใช้ YYYY-MM-DD เหมือนกัน [ตรวจแล้ว] สมมติฐานเดิมว่ารูปแบบเปลี่ยนยังไม่พบหลักฐาน แต่ยังไม่ได้ตรวจงวดกลาง                                                              | คงกฎเดิมไว้เป็นตาข่ายกันพลาด: แปลงด้วยรายการรูปแบบที่ระบุชุดเรียงลำดับลง ถ้าไม่เข้าเลยให้บันทึกไว้ ห้ามปล่อยให้เตารูปแบบเอง เพราะสลับวันกับเดือนได้เจียบ ๆ                                                |
| Q7 | โครงสร้างคอลัมน์เปลี่ยน | หนักกว่าที่คาดมาก [ตรวจแล้ว] ปี 2562 มี 78 คอลัมน์ ปี 2569 มี 99 และ ชื่อคอลัมน์เปลี่ยนทั้งระบบ: PROVNUM → CMS Certification Number (CCN) คอลัมน์อัตราลาออก (5) ชั่วโมงสุดสัปดาห์ (4) เครื่อง (7) พิกัด (1) ไม่มีในปี 2562 เลย | ทำตารางจับคู่ชื่อคอลัมน์แยกตามรุ่นของไฟล์ คอลัมน์ที่ยังไม่มีให้เป็นค่าว่าง และบันทึกตารางบันทึกการทำงานว่างวดใดขาดคอลัมน์ใด ใช้ Table 16 ของ NH_Data_Dictionary.pdf เป็นแหล่งอ้างอิงวันที่เปลี่ยน         |
| Q8 | หน่วยวัดไม่ตรงกัน       | งวด มิ.ย. 2569 เก็บเป็น เปอร์เซนต์ (มีฐาน 45.30 ช่วง 4–100) [ตรวจแล้ว] เทียบกับปี 2562 ไม่ได้เพราะยังไม่มีคอลัมน์นี้ (ดู Q7) จึงยัง เทียบข้ามยุคไม่ได้ [ยังไม่ตรวจ]                                                            | ตรวจจากค่ามัธยฐานของแต่ละงวด ถ้าน้อยกว่า 1.5 ให้คูณ 100 แล้วบันทึกการแปลงลงตาราง บันทึกการทำงาน กฎนี้ยังจำเป็น เพราะต้องรันกับงวดที่ยังไม่ได้เปิดดูอีกหลายสิบงวด                                          |

ตารางที่ 9: ปัญหาคุณภาพข้อมูลแปดประเภท ครอบคลุมทุกหัวข้อที่โจทย์ยกตัวอย่างไว้ คอลัมน์ขวาสุดเขียนเป็นภาษาที่แปลงเป็นโค้ดได้ทันที ซึ่งเป็นเจตนา — แผนที่แปลงเป็นโค้ดไม่ได้ คือแผนที่ยังคิดไม่จบ

## อย่าอ่าน CCN เป็นตัวเลข แม้แต่ครั้งเดียว

015009 เป็นรหัสประจำสถานพยาบาล ไม่ใช่จำนวน การอ่านเป็นตัวเลขทำให้กลายเป็น 15009 ซึ่งจะเชื่อมกับตารางอื่นไม่ติดแบบเจียบ ๆ — ไม่มี error มีแต่แถวที่หายไปจากผลลัพธ์

รหัสไปรษณีย์ก็เป็นแบบเดียวกัน (01234 ในรัฐทางตะวันออกเฉียงเหนือ) กฎที่ปลอดภัยคือ อ่านทุกคอลัมน์เป็นข้อความก่อนเสมอ แล้วค่อยแปลงเฉพาะคอลัมน์ที่เป็นตัวเลขจริง

## Fine ID ใช้เป็นคีย์กำจัดซ้ำได้ไม่ตลอดช่วง — ต้องมีสองระบบ

เอกสารฉบับก่อนวางคีย์ของ Fact 2 ไว้ที่ (ccn, วันที่, ประเภท, fine\_id) ตรวจจริงแล้วพบปัญหาสามชั้น [\[ตรวจแล้ว\]](#)

หนึ่ง — คอลัมน์นี้เพิ่มมี Table 16 ของคู่มือระบุว่า “202606 Penalties: Added Fine ID column after Penalty Type” แปลว่างวดก่อน มิ.ย. 2569 ไม่มีคอลัมน์นี้เลย ซึ่งคือเกือบทั้งโครงการ

สอง — วางทั้งหมดบนรายการระงับการจ่ายเงิน ในงวด มิ.ย. 2569 Fine ID เป็นค่าว่างครบทั้ง 2,470 แถวที่เป็น Payment Denial (ไม่ว่างเลยทั้ง 13,710 แถวที่เป็น Fine) จึงกำจัดซ้ำได้เฉพาะครั้งเดียวของตาราง

สาม — คีย์ธรรมชาติทดแทนไม่ปลอดภัย เมื่อมี Fine ID ค่าไม่ซ้ำเลยแม้แต่รายการเดียว (13,710 ค่าต่อ 13,710 แถว) แต่ถ้าใช้ (ccn, วันที่, ประเภท, จำนวนเงิน) แทน จะเหลือเพียง 13,424 กลุ่ม คือ กลืนค่าปรับจริงหายไป 286 รายการ (2.09%) คิดเป็นเงิน 2.66 ล้านดอลลาร์ (0.58%) เพราะสถานที่เดียวกันโดนปรับหลายรายการในวันเดียวกันด้วยจำนวนเงินเท่ากันได้จริง เช่น CCN 015060 วันที่ 2025-05-09 มีค่าปรับ \$5,782 สามรายการ (Fine ID 134643, 134644, 134645)

ข้อสรุปเชิงออกแบบ: Fact 2 ต้องมีคอลัมน์ fine\_id\_source บอกว่าแถวนั้นได้คีย์มาจากไหน แล้วกำจัดซ้ำแบบสองระบบ — งวดตั้งแต่ 202606 ใช้ Fine ID ตรง ๆ ส่วนงวดก่อนหน้าใช้คีย์ธรรมชาติ บวกลำดับที่ภายในกลุ่ม (row number ภายใน ccn+วันที่+ประเภท+จำนวนเงิน) เพื่อไม่ให้รายการที่เหมือนกันถูกรวม และต้องรายงานตัวเลข 2.09% นี้ ไว้ในข้อจำกัดของโครงการ

## ติตตรง ดีกว่าลบทิ้ง

ทุกกฎในตารางข้างบนที่เจอค่าผิดปกติ จะ ตีตรง is\_suspect ไว้ที่แถวนั้น ไม่ใช่ลบแถวทิ้ง เหตุผลสองข้อ

หนึ่ง — ค่าผิดปกติบางตัวคือของจริง เช่น อัตราการเข้าพัก 105% เกิดได้จริงเมื่อมีเตียงเสริมชั่วคราว

สอง — แดชบอร์ดจะมีสวิตช์ให้ผู้ใช้เลือกเองว่าจะรวมหรือไม่รวมแถวที่น่าสงสัย ซึ่งกลายเป็นตัวกรองที่หนึ่งในห้าตัวไปในตัว และทำให้ผู้ใช้เห็นว่าข้อมูลไม่สมบูรณ์แบบ แทนที่จะซ่อนไว้

## ภาคที่ 4

## คลังข้อมูล — Grain และ Star Schema

ภาคนี้ตอบคำถามว่า: หนึ่งแถวในตาราง Fact หมายความว่าอะไรกันแน่

### 12 สี่ขั้นตอนของ Kimball

การออกแบบเดินตามลำดับสี่ขั้นตอนมาตรฐาน ห้ามข้ามลำดับ เพราะขั้นหลังพึ่งขั้นก่อนหน้าทั้งหมด

#### 12.1 ขั้นที่ 1 — เลือกกระบวนการทางธุรกิจ

เลือก สองกระบวนการ เพราะทั้งคู่เป็นหัวใจของคำถาม และมี Grain ต่างกัน จึงต้องแยกตาราง Fact (ซึ่งโจทย์ระบุว่าได้คะแนนพิเศษ)

1. การติดตามผลการดำเนินงานรายงวด — CMS “ถ่ายรูป” สถานะของทุกแห่งทุกเดือน ไม่ใช่ธุรกรรม แต่เป็นสถานะ ณ เวลาหนึ่ง
2. การถูกลงโทษทางกฎระเบียบ — เกิดเป็นครั้ง ๆ มีวันที่ชัดเจนและมีมูลค่าเป็นเงิน

### 13 ขั้นที่ 2 — ประกาศ Grain


**Grain คือประโยคเดียวที่ต้องเขียนให้ได้ก่อนทำอย่างอื่น**

Grain คือคำตอบของคำถาม “หนึ่งแถวในตารางนี้แทนอะไรในโลกจริง” ถ้าตอบเป็นประโยคเดียวไม่ได้ แปลว่ายังออกแบบไม่เสร็จ และทุกอย่างที่สร้างต่อจากนั้นจะพังตามมา

| ตาราง Fact            | หนึ่งแถวหมายถึงอะไร                                                                                                                                                                                                     | ประเภทและเหตุผล                                                                                                                               |
|-----------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------|
| Fact_Facility_Monthly | หนึ่งแถว = สถานพยาบาลหนึ่งแห่ง (หนึ่ง CCN) ณ วันที่ CMS เผยแพร่ข้อมูลหนึ่งครั้ง<br>ตัวอย่าง: “CCN 015009 ตามข้อมูลที่เผยแพร่วันที่ 24 มิ.ย. 2569”                                                                       | Periodic Snapshot — บันทึกสถานะ ไม่ใช่เหตุการณ์ แถวถูกสร้างทุกงวดแม้ไม่มีอะไรเปลี่ยน ซึ่งเป็นสิ่งที่ต้องการ เพราะทำให้เส้นกราฟต่อเนื่องไม่ขาด |
| Fact_Penalty_Event    | หนึ่งแถว = บทลงโทษหนึ่งรายการ (ค่าปรับหนึ่งครั้ง หรือการระงับการจ่ายเงินหนึ่งครั้ง) ที่ CMS ส่งกับสถานพยาบาลหนึ่งแห่ง ในวันที่กำหนดโทษหนึ่งวัน<br>ตัวอย่าง: “ค่าปรับ 12,350 ดอลลาร์ กับ CCN 015009 วันที่ 3 มี.ค. 2568” | Transaction — เป็นเหตุการณ์จริง ณ จุดเวลา ไม่มีแถวถ้าไม่มีเหตุการณ์ ทำให้การรวมยอดค่าปรับเป็นการบวกที่ถูกต้องแท้จริง                          |

ตารางที่ 10: การประกาศ Grain ของทั้งสองตาราง Fact ประโยคตัวหนาคือสิ่งที่ต้องท่องได้ ส่วนตัวอย่างข้างใต้มีไว้เพื่อให้เห็นภาพว่าแถวจริงหน้าตาเป็นอย่างไร

### 13.1 ทำไมสองตารางนี้ถึงรวมกันไม่ได้



#### นี่คือเหตุผลที่ต้องแยกเป็นสองตาราง

ถ้ายึดไว้ตารางเดียว งวดที่ไม่มีค่าปรับจะต้องใส่ศูนย์ และงวดที่มีค่าปรับสองครั้งจะต้องทำสำเนาแถวสถานะขึ้นมาสองแถว ทำให้ข้อมูลงวดและจำนวนเตียงถูกนับซ้ำทันที

รูปที่ 4: Grain ที่ต่างกันของสอง Fact เมื่อวางบนแกนเวลาเดียวกัน แถบน้ำเงินเกิดสมำเสมอตามงวดที่ CMS เผยแพร่ ส่วนแถบส้มเกิดกระจายตามเหตุการณ์จริง สองจังหวะนี้อยู่ในตารางเดียวกันไม่ได้

#### ProviderInfo มีคอลัมน์ค่าปรับอยู่แล้ว แต่ใช้แทน Fact 2 ไม่ได้

คอลัมน์ Total Amount of Fines in Dollars ใน ProviderInfo คือยอดรวมของ หน้าต่างหมุน 3 ปี [ตรวจแล้ว] ยืนยันสองทาง — คู่มือระบุว่าแฟ้ม Penalties คือ “a list of the fines...in the last three years” และเมื่อรวมยอดจากแฟ้ม Penalties เองแล้วเทียบกลับ ได้ตรงกัน ครบทั้ง 6,563 แห่ง ทั้งจำนวนเงินและจำนวนรายการ ส่วนวันที่ในแฟ้มก็อยู่ในช่วง 2023-06-17 ถึง 2026-05-13 เทียบกับงวด 2026-06-01 พอดี

มันจึงรวมข้ามสถานที่ได้ แต่ รวมข้ามงวดไม่ได้ เพราะจะนับซ้ำ คำถาม BQ7 ที่ถามว่า “ค่าปรับกระจุกในช่วงเวลาใด” จึงตอบจากคอลัมน์นี้ไม่ได้เลย — นี่คือเหตุผลเชิงออกแบบของ Fact 2 ไม่ใช้การเพิ่มตารางเพื่อเอาคะแนนพิเศษ

### หน้าตาของหน้าแดชบอร์ด — ค่าปรับ “หายไป” ได้เอง

ตอนแรกเอกสารนี้เขียนว่าคอลัมน์นั้นเป็น “ยอดสะสม” ซึ่งผิด และความต่างนี้สำคัญกว่าที่เห็น ยอดสะสมจะโตขึ้นอย่างเดียว แต่ หน้าตาของหน้าแดชบอร์ด ค่าปรับที่เกิน 3 ปีจะ หายออกจากแฟ้มไป เจียบ ๆ ทำให้ยอดของสถานที่หนึ่ง ลดลงระหว่างสองงวดได้ทั้งที่ไม่มีอะไรผิดพลาด

ผลที่ตามมาสองข้อ: หนึ่ง — ห้ามตีความยอดที่ลดลงว่าเป็น “ข้อมูลพัง” สอง — Fact 2 ที่สะสมค่าปรับ จากทุกงวดจะเก็บประวัติได้ ยาวกว่า ที่แฟ้มงวดใดงวดเดียวจะให้ได้ ซึ่งเป็นคุณค่าที่แท้จริงของการทำ คลังข้อมูล ไม่ใช่แค่คัดลอกไฟล์มาเก็บ


## 14 ขั้นที่ 3 — เลือก Dimensions

ได้ **หกตาราง** เกินเกณฑ์ขั้นต่ำห้าตาราง โดยห้าตัวแรกเป็น *Conformed Dimension* ที่ใช้ร่วมกันทั้งสอง Fact ซึ่งเป็นสิ่งที่ทำให้ถามข้ามตารางได้ เช่น “ค่าปรับเฉลี่ยต่อเตียง เทียบกับ คะแนนดาวเฉลี่ย ในรัฐเดียวกัน”

| Dimension        | ชนิด          | ใช้กับ  | เหตุผล                                                                                                                                     |
|------------------|---------------|---------|--------------------------------------------------------------------------------------------------------------------------------------------|
| Dim_Date         | —             | ทั้งสอง | โจทยบังคับให้มี ทำที่ระดับวันเพื่อรองรับ Fact 2 และ ใช้ได้หลายบทบาท: วันเผยแพร่ วันกำหนดโทษ วัน ตรวจ วันรับรองครั้งแรก                     |
| Dim_Facility     | SCD ชนิดที่ 2 | ทั้งสอง | ต้องเป็นชนิดที่ 2 เพราะสถานะ Special Focus และ ไอคอนการทารุณกรรม <i>เปลี่ยนไปตามเวลา</i> ถ้าเขียน ทับจะตอบ BQ6 ไม่ได้ว่าเคยติดธงแดงหรือไม่ |
| Dim_Geography    | ชนิดที่ 1     | ทั้งสอง | รวมรหัสไปรษณีย์ เมือง เคาน์ตี รัฐ ภูมิภาค ไว้ตาราง เดียว เป็น star ไม่ใช่ snowflake และเป็นจุดเชื่อมกับ ข้อมูลประชากร                      |
| Dim_Ownership    | ชนิดที่ 1     | ทั้งสอง | แยกออกมาเพราะ BQ2 ต้องการแบ่งกลุ่มด้วยรูปแบบ การถือครองโดยตรง และค่าดิบมีหลายค่าที่ต้องยุบ เหลือสามกลุ่ม                                   |
| Dim_Chain        | ชนิดที่ 1     | ทั้งสอง | รองรับ BQ8 เก็บรหัสเครือ ขนาดเครือ และธงว่าเป็น อิสระหรือไม่                                                                               |
| Dim_Penalty_Type | ชนิดที่ 1     | Fact 2  | แยก “ค่าปรับเป็นเงิน” ออกจาก “ระงับการจ่ายเงิน” ซึ่งมีนัยทางการเงินต่างกันมาก                                                              |

**ตารางที่ 11:** หก Dimension และเหตุผลที่ต้องมีแต่ละตัว ตัวที่ต้องระวังที่สุดคือ Dim\_Facility เพราะเป็นชนิดที่ 2 ตัวเดียวในผัง

## 14.1 SCD ชนิดที่ 2 ทำงานอย่างไร




รูปที่ 5: การทำงานของ SCD ชนิดที่ 2 บน Dim\_Facility เมื่อสถานะเผื่อระวังเปลี่ยน ระบบสร้างแถวใหม่แทนการเขียนทับ ทำให้คำถามอย่าง คะแนนตกหลังติดบัญชีเผื่อระวังหรือไม่ ตอบได้

### ผลข้างเคียงของ SCD ชนิดที่ 2 ที่ลืมนับน้อย

เมื่อ facility\_key ไม่ใช่หนึ่งต่อหนึ่งกับ CCN อีกต่อไป การเชื่อมตารางด้วย CCN เฉย ๆ จะได้แถวเกินมาเป็นทวีคูณ

ต้องเลือกเวอร์ชันที่ตรงช่วงเวลาเสมอ นั่นคือ  $\text{effective\_date} \leq \text{วันที่ของข้อเท็จจริง} < \text{expiry\_date}$  กฎข้อนี้ต้องเขียนไว้ในโค้ด ETL เป็นฟังก์ชันเดียวที่ทุกที่เรียกใช้ ไม่ใช่เขียนเงื่อนไขซ้ำในทุก query

## 15 ชั้นที่ 4 — ผัง Star Schema



รูปที่ 6: ผัง Star Schema สองตาราง Fact และหก Dimension เส้นทึบเขียวคือความสัมพันธ์หลัก เส้นประน้ำเงินคือ conformed dimension ที่ใช้ร่วมกันทั้งสอง Fact — PK คือคีย์หลัก FK คือคีย์นอก DD คือ degenerate dimension ที่เก็บรหัสจากระบบต้นทางไว้ในตาราง Fact เอง

### ทำไมวางผังแบบนี้

ผัง Star Schema ที่มีสอง Fact มักถูกวาดกว้าง จนต้องหมุนหน้ากระดาษเป็นแนวนอน เอกสารนี้เล็งด้วยการ วาง Fact ซ้อนกันแนวตั้ง แล้ววาง Dimension ที่ใช้ร่วมกันไว้สองข้าง ผังจึงสูงกว่ากว้างและพอดีหน้า A4 แนวตั้ง และได้ผลพลอยได้คือ ดูออกทันทีว่า Dimension ตัวใดใช้ร่วมกัน — ตัวที่มีเส้นออกทั้งขึ้นและลง

## 16 ข้อควรระวังของผังนี้

1. **Dim\_Date** ต้องย้อนไปไกลกว่าที่คิด — คอลัมน์วันที่ได้รับรองครั้งแรก อาจย้อนไปถึงทศวรรษ 2500 จึงสร้างช่วง 1960-01-01 ถึง 2027-12-31 (ราว 24,800 แถว ซึ่งเล็กมาก) พร้อมแถวพิเศษ date\_key = -1 สำหรับค่าที่ไม่ทราบ
2. **ccn** ถูกเก็บเป็น degenerate dimension ในทั้งสอง Fact — เพื่อให้ตรวจสอบย้อนกลับ ไปยังไฟล์ดิบได้โดยไม่ต้องเชื่อมตาราง และทำให้ตรวจสอบการจัดข้อมูลง่ายขึ้น
3. ค่าเฉลี่ยของเครื่องจะไม่เก็บใน Dim\_Chain — เพราะ CMS คำนวณใหม่ทุกเดือน ถ้าเก็บไว้ในตาราง Dimension แบบเขียนทับ กราฟย้อนหลังจะใช้ค่าปัจจุบันทั้งหมดและผิด จะคำนวณจากตาราง Fact ตอนสอบถามแทน
4. **is\_suspect** ติดอยู่กับแถว Fact ไม่ใช่ Dimension — เพราะเป็นคุณสมบัติของ การวัดครั้งนั้น ไม่ใช่ของสถานที่

## ภาคที่ 5

## ETL และ Dashboard — แผนงานถัดไป

ภาคนี้ตอบคำถามว่า: ขั้นตอนต่อไปต้องสร้างอะไรบ้าง (ยังไม่ได้เริ่ม)

## 17 กระบวนการ ETL ห้าขั้น

| ขั้น      | สิ่งที่ทำ                                                                                                                                     |
|-----------|-----------------------------------------------------------------------------------------------------------------------------------------------|
| Extract   | เรียก API ปลายทาง A เพื่อได้รายการ snapshot ทั้งหมด เลือกเฉพาะรายไตรมาส ดาวน์โหลด ZIP โดยข้ามไฟล์ที่มีอยู่แล้ว แล้วคลายเฉพาะ 6 CSV ที่ใช้จริง |
| Clean     | ใช้กฎ Q1-Q8 จากภาค 3 ทุกกฎเขียนเป็นฟังก์ชันแยก และเขียนผลลงตารางบันทึกการทำงาน ว่า งดใดแกอะไรไปกี่แถว                                         |
| Transform | สร้าง surrogate key สร้าง Dim_Date ทำ SCD ชนิดที่ 2 ให้ Dim_Facility และคำนวณ measure ที่หาได้จากตัวอื่น                                      |
| Integrate | เชื่อม CMS กับ VBP กับข้อมูลประชากร ด้วย CCN และรหัสรัฐ พร้อมรายงานอัตราการเชื่อมต่อสำเร็จ                                                    |
| Load      | เขียนลงฐานข้อมูลไฟล์เดียว แล้วรันการตรวจสอบหลังโหลด: คีย์นอกครบทุกตัว ไม่มีคีย์หลักซ้ำ และจำนวนแถวตรงกับที่ตั้งมา                             |

ตารางที่ 12: ห้าขั้นของ ETL ตามที่โจทย์กำหนด หลักการที่ยึดคือรันซ้ำได้โดยไม่ต้องแก้มือ และรันซ้ำแล้วต้องได้ผลเหมือนเดิม

## 18 แผนแดชบอร์ด

โจทย์กำหนด: measure สรุปอย่างน้อย 3 ตัว กราฟอย่างน้อย 5 กราฟ กราฟตามช่วงเวลาอย่างน้อย 1 กราฟ เปรียบเทียบอย่างน้อย 1 ตัวกรองอย่างน้อย 2 และข้อเสนอแนะอย่างน้อย 5 ข้อ

| #  | กราฟ                                                            | ชนิด                    | ตอบข้อใด |
|----|-----------------------------------------------------------------|-------------------------|----------|
| C1 | การ์ดสรุป: อัตราการเข้าพัก คะแนนเฉลี่ย ค่าปรับรวม ชั่วโมงพยาบาล | ตัวเลขสรุป              | ภาพรวม   |
| C2 | อัตราการเข้าพักและคะแนนเฉลี่ยรายไตรมาส 2562-2569                | เส้น (ตามช่วงเวลา)      | BQ5      |
| C3 | เปรียบเทียบคุณภาพและค่าปรับตามรูปแบบการถือครอง                  | แท่งกลุ่ม (เปรียบเทียบ) | BQ2      |
| C4 | ชั่วโมงพยาบาล เทียบกับ คะแนนดาว (จุดละหนึ่งแห่ง)                | กระจาย + เส้นแนวโน้ม    | BQ3      |
| C5 | เตียงต่อผู้สูงอายุพันคน รายรัฐ                                  | แผนที่หรือแท่งเรียง     | BQ1      |
| C6 | มูลค่าค่าปรับรายไตรมาส แยกตามประเภทบทลงโทษ                      | แท่งซ้อน                | BQ7      |
| C7 | ตารางเผื่อระวัง: สถานที่ที่คะแนนลดต่อเนื่อง                     | ตาราง + แถบสี           | BQ6      |
| C8 | อัตราลาออก เทียบกับ คะแนน แบ่งตามขนาดเครือ                      | กล่อง                   | BQ4, BQ8 |

ตารางที่ 13: แดตากราฟและคำถามที่แต่ละกราฟตอบ ไม่มีกราฟใดที่ไม่ผูกกับคำถามธุรกิจ ซึ่งเป็นข้อกำหนดของโจทย์โดยตรง

ตัวกรองหัวข้อ: ช่วงเวลา · รัฐ · รูปแบบการถือครอง · ขนาดเครือ · สวิตช์รวมหรือไม่รวมแถวที่ติดธง is\_suspect

## 19 คะแนนพิเศษที่ตั้งเป้า

1. สองตาราง Fact — โจทย์ระบุว่าได้คะแนนพิเศษโดยตรง และมีเหตุผลเชิงออกแบบรองรับ
2. การใช้ API — ปลายทาง JSON ของ CMS [\[ตรวจสอบแล้ว\]](#)
3. ไปป์ไลน์อัตโนมัติและการโหลดแบบเพิ่มเติม — ข้าม snapshot ที่โหลดแล้ว
4. การตรวจสอบคุณภาพข้อมูลอัตโนมัติ — กฎ Q1-Q8 พร้อมตารางบันทึกการทำงาน
5. แดชบอร์ดด้วยเครื่องมือสมัยใหม่ — Streamlit บนฐานข้อมูล DuckDB
6. ชุดข้อมูลสำหรับต่อยอดการพยากรณ์ — ตารางแบนสำหรับทำนายว่า สถานที่ใดจะถูกปรับในไตรมาสถัดไป

## 20 สิ่งที่ต้องทำก่อนเริ่มพัฒนา

สื่อก่อนตรวจสอบเสร็จแล้ว สรุปผลไว้ที่นี่ พร้อมชี้ว่าคำตอบไปเปลี่ยนอะไรในเอกสาร

| # | สิ่งที่สงสัย                        | ผลการตรวจ                                                                                                                                                                                                                                                       | กระทบอะไร                                                            |
|---|-------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------|
| 1 | ยอดค่าปรับใน ProviderInfo สะสมกี่ปี | 3 ปีแบบหน้าต่างหมุน ไม่ใช่สะสมตลอดกาล<br>[ตรวจแล้ว] คู่มือระบุว่า Penalties คือ “fines...in the last three years” และพิสูจน์<br>ซ้ำด้วยข้อมูลจริง: ยอดใน ProviderInfo ตรงกับ<br>ผลรวมจากแฟ้ม Penalties ครบทั้ง 6,563 แห่ง<br>(100%) ทั้งจำนวนเงินและจำนวนรายการ | เหตุผลของ Fact 2 แข็งขึ้น แต่<br>ต้องเปลี่ยนถ้อยคำ (ดูภาคผนวก<br>ข)  |
| 2 | ปี 2562 ขาดคอลัมน์อะไรบ้าง          | ขาดมากกว่าที่คิด: 78 vs 99 คอลัมน์ และ<br>เปลี่ยนระบบตั้งชื่อทั้งหมด [ตรวจแล้ว] อัตราลา<br>ออก ชั่วโมงสุดสัปดาห์ เครื่อ พิกัด ไม่มีเลย                                                                                                                          | Q7 ยกกระดับความรุนแรง และ<br>เพิ่มงานทำตารางจับคู่ชื่อคอลัมน์        |
| 3 | Census API ไม่คืนค่า                | ต้องใช้ API key [ตรวจแล้ว] เซิร์ฟเวอร์ตอบ<br>302 ไปหน้า missing_key.html จึงได้ body<br>ว่างโดยไม่มี error ทางถอยแบบไม่ต้องใช้คีย์<br>ทดสอบแล้วว่าใช้ได้                                                                                                        | BQ1 ไม่ถูกล็อกอีกต่อไป (ดู<br>หัวข้อแหล่งเสริม)                      |
| 4 | Fine ID ซ้ำข้าม snapshot ใหม่       | ไม่ซ้ำเลยภายในงวด (13,710 ค่า/13,710 แถว)<br>แต่ใช้ไม่ได้ทั้งช่วง [ตรวจแล้ว] เพราะเพิ่งมี<br>ตั้งแต่งวด 202606 และว่างทั้งหมดบนรายการ<br>ระงับการจ่ายเงิน                                                                                                       | คีย์ของ Fact 2 ต้องออกแบบใหม่<br>เป็นสองระบบ (ดูกล่องแดงใน<br>ภาค 3) |

ตารางที่ 14: ผลการตรวจสอบข้อที่ค้างไว้ ทุกข้อได้คำตอบจากข้อมูลจริงหรือคู่มือฉบับทางการ ไม่มีข้อใดที่ยังต้องเดา

## ที่ยังเหลือ

1. เดิมหมายเลขกลุ่มและชื่อสมาชิกสามคนลงหน้าปก
2. ขอ Census API key (ฟรี ใช้เวลาไม่กี่นาที) หรือยืนยันว่าจะใช้ทางถอย
3. เปิด snapshot งวดกลาง (ราวปี 2565) เพื่อปิดช่องว่างของ Q6 และ Q8 ซึ่งตอนนี้ยืนยันได้แค่สองปลาย

## ภาคผนวก

### A อภิธานศัพท์ ไทย-อังกฤษ

| ไทย                         | อังกฤษ                           | ความหมายย่อ                                                       |
|-----------------------------|----------------------------------|-------------------------------------------------------------------|
| คลังข้อมูล                  | data warehouse                   | ฐานข้อมูลที่จัดโครงสร้างไว้เพื่อการวิเคราะห์ ไม่ใช่เพื่อรับรายการ |
| ความละเอียดของข้อมูล        | grain                            | หนึ่งแถวในตาราง Fact แทนอะไรในโลกจริง                             |
| ตารางข้อเท็จจริง            | fact table                       | ตารางกลางที่เก็บตัวเลขที่ต้องการวัด                               |
| ตารางมิติ                   | dimension table                  | ตารางรอบข้างที่บอกว่าตัวเลขนั้นเป็นของใคร ที่ไหน เมื่อไร          |
| มิติร่วม                    | conformed dimension              | ตารางมิติที่ใช้ร่วมกันได้หลายตาราง Fact                           |
| มิติเสื่อม                  | degenerate dimension             | รหัสจากระบบต้นทางที่เก็บไว้ในตาราง Fact เอง                       |
| คีย์แทน                     | surrogate key                    | คีย์ที่ระบบสร้างเอง ไม่ใช่รหัสจากต้นทาง                           |
| มิติที่เปลี่ยนช้า ชนิดที่ 2 | slowly changing dimension type 2 | เก็บประวัติด้วยการเพิ่มแถวใหม่ ไม่เขียนทับ                        |
| สถานะรายงวด                 | periodic snapshot                | ตาราง Fact ที่บันทึกสถานะทุกงวด แม้ไม่มีการเปลี่ยนแปลง            |
| ธุรกรรม                     | transaction fact                 | ตาราง Fact ที่มีแถวเฉพาะเมื่อเกิดเหตุการณ์                        |
| การรวมค่าได้                | additivity                       | บอกว่า measure นั้นเอาไปบวกกันตรง ๆ ได้หรือไม่                    |
| อัตราการเข้าพัก             | occupancy rate                   | ผู้พักอาศัยเฉลี่ยต่อวัน หาดด้วย จำนวนเตียงที่รับรอง               |
| ชั่วโมงพยาบาลต่อคนต่อวัน    | hours per resident day (HPRD)    | ชั่วโมงงานพยาบาลทั้งหมด หาดด้วย จำนวนผู้พักอาศัย                  |
| อัตราการลาออก               | turnover rate                    | สัดส่วนพนักงานที่ลาออกในรอบหนึ่งปี                                |
| การโหลดแบบเพิ่มเติม         | incremental load                 | โหลดเฉพาะข้อมูลใหม่ ไม่โหลดซ้ำทั้งหมด                             |
| รหัสรับรองสถานพยาบาล        | CMS Certification Number (CCN)   | รหัสหลักประจำสถานพยาบาล มีศูนย์นำหน้าได้                          |
| สถานะเฝ้าระวังพิเศษ         | Special Focus Facility (SFF)     | สถานะที่ CMS ให้กับสถานที่ที่มีปัญหาคุณภาพซ้ำซาก                  |
| การจัดซื้อตามคุณค่า         | value-based purchasing (VBP)     | โครงการที่ผูกเงินที่จ่ายให้เข้ากับผลลัพธ์ด้านคุณภาพ               |

## B คอลัมน์สำคัญของ NH\_ProviderInfo ที่จะใช้จริง

จาก 99 คอลัมน์ โครงการนี้ใช้จริงราว 30 คอลัมน์ ที่เหลือเป็นเชิงอรรถและรายละเอียด การตรวจรายรอบที่ไม่ได้ใช้

| คอลัมน์ต้นทาง                                       | ไปเป็นอะไร          | หมายเหตุ                                                                                |
|-----------------------------------------------------|---------------------|-----------------------------------------------------------------------------------------|
| CMS Certification Number (CCN)                      | ศิรัธรรมชาติ        | ต้องอ่านเป็นข้อความ (ดูกฎ Q1)                                                           |
| Provider Name, Legal Business Name                  | Dim_Facility        | เปลี่ยนได้เมื่อเปลี่ยนเจ้าของ                                                           |
| City/Town, State, ZIP Code, County/Parish, Urban    | Dim_Geography       |                                                                                         |
| Latitude, Longitude                                 | Dim_Geography       | ใช้ทำแผนที่                                                                             |
| Ownership Type                                      | Dim_Ownership       | ต้องยุบเหลือสามกลุ่ม (กฎ Q5)                                                            |
| Chain Name, Chain ID, Number of Facilities in Chain | Dim_Chain           |                                                                                         |
| Special Focus Status, Abuse Icon                    | Dim_Facility (SCD2) | เหตุผลที่ต้องใช้ชนิดที่ 2                                                               |
| Number of Certified Beds                            | measure             | ตัวหารของอัตราการใช้พัก                                                                 |
| Average Number of Residents per Day                 | measure             | ตัวตั้งของอัตราการใช้พัก                                                                |
| Reported Total Nurse Staffing HPRD                  | measure M3          |                                                                                         |
| Reported RN Staffing HPRD                           | measure             | แยกดูสัดส่วนพยาบาลวิชาชีพ                                                               |
| Total Nursing Staff Turnover                        | measure M4          | ระวังหน่วยวัด (กฎ Q8)                                                                   |
| Overall Rating และคะแนนย่อยอีก 3 ตัว                | measure M7          | มีคอลัมน์ footnote คู่กัน                                                               |
| Rating Cycle 1 Total Number of Health Deficiencies  | measure M8          |                                                                                         |
| Total Amount of Fines in Dollars                    | ไม่ใช่              | ยอดรวม หน้าต่างหมุน 3 ปี ไม่ใช่ยอดสะสมตลอดกาล ใช้ Fact 2 แทน <a href="#">[ตรวจแล้ว]</a> |
| Processing Date                                     | snapshot_date_key   | วันที่ของ Grain                                                                         |

**ตารางที่ 16:** การจับคู่คอลัมน์ต้นทางกับปลายทาง แถวสุดท้ายที่ระบุว่าไม่ใช่ คือการตัดสินใจที่สำคัญที่สุดในตารางนี้ และเป็นเหตุผลที่มีตาราง Fact ที่สอง

## C คำสั่งที่ใช้ตรวจสอบตัวเลขในเอกสารนี้

ตัวเลขทุกตัวที่กำกับ [\[ตรวจแล้ว\]](#) มาจากการรันคำสั่งเหล่านี้จริง ถ้า CMS ออกข้อมูลใหม่ แล้วรันซ้ำได้ผลต่างไป ตัวเลขในเนื้อหาต้องแก้ตาม

### 1. รายการ snapshot ทั้งหมด

```
curl -sS "https://data.cms.gov/provider-data/api/1/archive/aggregate/theme/nursing-homes/relative"
```

### 2. ดาวน์โหลดและดูรายชื่อไฟล์ใน snapshot

```
curl -sS -o nh.zip "https://data.cms.gov/provider-data/sites/default/files/dataset-archives/theme/nursing-homes/nursing-homes_2026-06-24.zip" && unzip -l nh.zip
```

3. **นับแถวและคอลัมน์ของ CSV** — คลาย ZIP แล้วอ่านด้วย pandas โดยกำหนด dtype=str และ encoding='latin-1' (ไฟล์ไม่ใช่ UTF-8 ล้วน)
4. **ดึงแถวตัวอย่างจาก API**  

```
curl -sS "https://data.cms.gov/provider-data/api/1/datastore/query/4pq5-n9py/0?limit=1"
```
5. **หาสาเหตุที่ Census คืบค่าง** — ดู redirect แทนที่จะดู body  

```
curl -sS -o /dev/null -w "%{http_code} %{redirect_url}" \
  "https://api.census.gov/data/2023/acs/acs5?get=NAME,
  B01001_001E&for=state:*"
  คืบ 302 https://api.census.gov/data/missing_key.html
```
6. **ยืนยันว่ายอดค่าปรับเป็นหน้าต่าง 3 ปี** — รวม Fine Amount จาก Penalties ตาม CCN แล้วเทียบกับ Total Amount of Fines in Dollars ใน ProviderInfo ต้องตรงกัน 100%
7. **ยืนยันว่า Fine ID จำเป็น** — นับ unique() ของ Fine ID เทียบกับจำนวนกลุ่มของ (CCN, Penalty Date, Penalty Type, Fine Amount) ผลต่างคือจำนวนค่าปรับที่ศิษย์ธรรมชาติดึงหาย
8. **เทียบโครงสร้างคอลัมน์ข้ามยุค** — คลาย ProviderInfo\_Download.csv จาก nursing-homes\_2019-01-17.zip แล้วเทียบ set(columns) กับงวดปัจจุบัน

## D แหล่งอ้างอิง

| แหล่ง                                                                                                                    | เกี่ยวข้องกับเอกสารอย่างไร                                                                         |
|--------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------|
| CMS Provider Data Catalog — Nursing Homes<br><a href="https://data.cms.gov/provider-data">data.cms.gov/provider-data</a> | แหล่งข้อมูลหลักทั้งหมด ต้องอ้างอิงในรายงานฉบับส่งและในวิดีโอ                                       |
| CMS Nursing Home Five-Star Quality Rating System — Technical Users' Guide                                                | นิยามของคะแนนดาวและวิธีคำนวณ ต้องใช้ตอนอธิบายว่า M7 หมายถึงอะไร                                    |
| NH_Data_Dictionary.pdf (อยู่ใน ZIP)                                                                                      | คำจำกัดความของทุกคอลัมน์ ต้องเปิดก่อนเริ่ม ETL เพื่อยืนยันข้อสงสัยเรื่องยอดสะสมของค่าปรับ          |
| Kimball & Ross — The Data Warehouse Toolkit                                                                              | ที่มาของสี่ขั้นตอนการออกแบบ และของคำว่า periodic snapshot กับ transaction fact ซึ่งเป็นแกนของภาค 4 |

- group project/69-1-Mini DW & Dashboard-1.pdf — โจทย์ต้นฉบับ พร้อมเกณฑ์ให้คะแนน  
หกหมวด
- PROGRESS.md — บันทึกความคืบหน้าสะสมของทั้งรายวิชา

---

เอกสารนี้เป็นแผนการออกแบบก่อนลงมือพัฒนา รูปทุกรูปวาดด้วย TikZ ไม่ใช่ผลลัพธ์จากการรันจริง ตัวเลขขนาดข้อมูลทุกตัว  
ที่กำกับ **[ตรวจแล้ว]** ตรวจสอบซ้ำได้ด้วยคำสั่งในภาคผนวก ค ส่วนที่กำกับ **[ยังไม่ตรวจ]** ยังเป็นสมมติฐาน ห้ามนำไปอ้างใน  
รายงานฉบับส่งจนกว่าจะพิสูจน์แล้ว